

Sortierverfahren 2



- Sie kennen das Prinzip: "Teile und Herrsche"
- Sie kennen zwei schnelle Sortierverfahren: Quicksort, Distribution Sort
- Sie können Algorithmen mittels Parallelisierung optimieren



Teile und Herrsche

Das Prinzip "Teile und Herrsche"

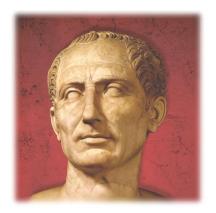
School of Engineering

Teile und Herrsche - abgekürzt: TUH

Andere Bezeichnungen dieses Prinzips:

Divide et impera

Divide and conquer, Divide and rule



- Divide et impera wird fälschlicherweise Cäsar zugeschrieben
- Zerlege das Problem in kleinere, einfacher zu lösende Teile
 - Spezialfall: Teil = Ursprungsproblem mit kleinerem Bereich
- Löse die so erhaltenen Teilprobleme
- Füge die Teillösungen wieder zu einem Ganzen zusammen

Teile und Herrsche bei Sortieralgorithmen



Sortieralgorithmen nach dem Prinzip Teile und Herrsche.

```
if (Menge der Datenobjekte klein genug)
    Ordne sie direkt;
else {
    Teilen: Zerlege die Menge in Teilmengen;
    Ausführen: Sortiere jede der Teilmengen;
    Vereinigen: Füge die Teilmengen geordnet zusammen;
}
```

Solche Algorithmen sind typischerweise rekursiv:

```
Sort (Menge a)
    if (Menge der Datenobjekte klein genug)
        Ordne sie direkt;
    else {
        Zerlege in zwei Teilmengen
        Sort(Teilmenge1); Sort(Teilmenge2)
        Füge Teilmengen geordnet zusammen
    }
}
```

Bei der Zerlegung sollten die Teile möglichst gleich gross sein.

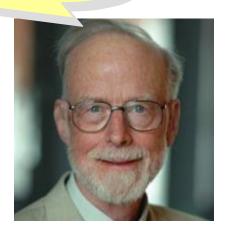


Idee des Quicksort

Zh School of Engineering

 1960: von dem britischen Informatiker C.A.R. Hoare Ich stelle fest, dass es zwei Wege gibt, ein Software-Design zu erstellen, entweder so einfach, dass es offensichtlich keine Schwächen hat, oder so kompliziert, dass es keine offensichtlichen Schwächen hat. Die erste Methode ist weitaus schwieriger.

- Entstehung
 - 1960 waren noch keine schnellen Sortieralgorithmen bekannt.
 - man versuchte damals Sortierverfahren durch raffinierte Assemblerprogrammierung zu beschleunigen.
- Quicksort mit naheliegenden Verbesserungen ist
 - einer der schnellsten bekannten allgemeinen Sortieralgorithmen
 - theoretisch gut verstanden.



Hoare zeigte dadurch, dass es sinnvoll sein kann, nach **besseren Algorithmen** zu suchen, als vorhandene Algorithmen durch ausgefeilte Programmierung zu beschleunigen.



Die Grundidee besteht darin, das vorgegebene Problem nach dem bereits genannten Motto Teile und Herrsche in einfachere Teilaufgaben zu zerlegen:

- nehme irgendeinen Wert W der Teil von A ist zum Beispiel den mittleren
- konstruiere eine Partitionierung des Sortierfeldes A in Teilmengen A₁ und A₂ mit folgenden Eigenschaften:



- $\bullet A = A_1 \cup A_2 \cup \{W\}$
- Alle Elemente von A₁ sind ≤ W (aber noch evtl. unsortiert).
- Alle Elemente von A₂ sind ≥ W (aber noch evtl. unsortiert).

Wenn jetzt A_1 und A_2 sortiert werden, ist das Problem gelöst.

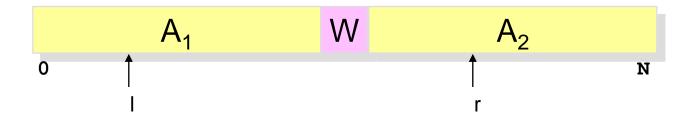


```
Methode Sortiere (A) {
   Konstruiere die Partition A = A<sub>1</sub> W A<sub>2</sub>;
   Sortiere A<sub>1</sub>;
   Sortiere A<sub>2</sub>;
}
```

noch zu lösendes Problem:

finden eines Wertes W, so dass A₁ und A₂ möglichst gleich gross sind.





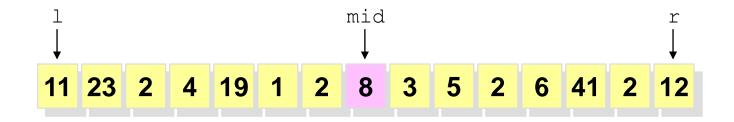
Die Konstruktion der Partition erfolgt durch:

- wähle ein Element W
- suche von links ein Element, das auf falscher Seite ist, d.h. A[I] ≥ W
- suche von rechts ein Element, das auf falscher Seite ist, A[r] ≤ W
- vertausche von A[I] und A[r]
- wiederhole obige Schritte bis I und r sich kreuzen, d.h. $l \ge r$.

Aufgabe



Führen Sie die erste Partionierung mit dem Algorithmus auf der vorhergehenden Seite an dem folgenden Beispiel durch.



Quicksort: Wahl des Pivots



Bestimmen des genau Median Wertes aufwendig -> Laufzeitvorteil von Quicksort ginge wieder verloren

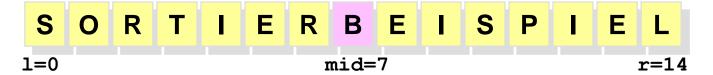
W wird lediglich geschätzt

- folgende Pivotwahlen sind möglich (Franz. Pivot = Drehpunkt)
 - A[I] das (der Position nach) linke Element von A;
 - A[r] das (der Position nach) rechte Element von A;
 - A[mid] das (der Position nach) mittlere Element von A mit mid = (l+r)/2
- Strategie 1: nehme eines der drei Elemente
- Strategie 2: nehme das (wertmässig) mittlere der drei Elemente
- Strategie 3: nehme das arithmetisch Mittel der drei Elemente

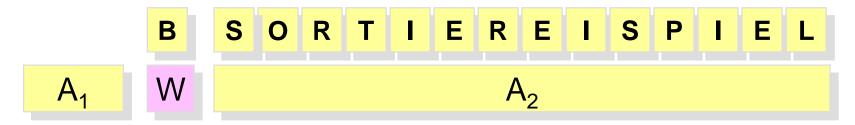
Schlechte Pivotwahl



- Gutes Pivot-Element ist nicht unbedingt das Element, welches der Position nach in der Mitte liegt.
- die Möglichkeit einer ungünstigen Verteilung der Daten:
 - durch die Partitionierung in eine Hälfte der Partition sehr viele und in die andere Hälfte sehr wenige Daten gelangen.
- Bei unserem Beispiel ergibt sich folgende Situation:



 Bei der Wahl von A[mid] als Pivot-Element ergibt sich ungünstige Partitionierung: A₁ ist leer und A₂ ist gerade mal ein Element kleiner als A.



Quicksort: Wahl des Pivots



- von entscheidender Bedeutung für die Effizienz von Quicksort
- optimal wäre ein Element, das A in zwei gleich grosse Teile partitioniert
- W muss so bestimmt werden, dass gleich viele Werte grösser wie kleiner als W sind:



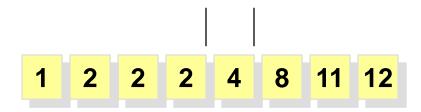
• Vorsicht: ist i.A. nicht gleich dem Mittelwert: $\sum x / n$:



Aufgabe: Anwendung Median, Mittelwert



 Ein Lehrer möchte, dass der Schnitt einer Prüfung genau 4 beträgt. Welche Punktzahl muss er für eine 4 fordern; Punktedurchschnitt 5.25*.



 Ein anderer Lehrer möchte, dass lediglich die Hälfte der Schüler eine genügende Note bekommt. Welche Punktzahl muss er jetzt für eine 4 fordern (ohne Runden)**.

^{*} natürlich wird ein Lehrer das nie so machen. Noten werden immer gerecht vergeben und anhand eines vorher festgelegten Bewertungsmassstabes bestimmt.

^{**} spätestens jetzt dürfte klar sein, dass das Beispiel völlig aus der Luft gegriffen ist und absolut keinen Bezug zur Realität hat.

Pivotwahl nach sog. Median Methode



Die drei Elemente A[I], A[mid] und A[r] werden vorsortiert und man nimmt das dem Werte nach **mittlere dieser drei Werte**.

vorsortieren:

```
int mid = (l+r)/2;
if (a[l] > a[mid]) swap(a, l, mid);
if (a[mid] > a[r]) swap(a, mid, r);
if (a[l] > a[mid]) swap(a, l, mid);
int p = a[mid];
if (r-l > 2) {...
```



Partition mit Median Methode



Dadurch ergibt sich eine bessere Pivot Wahl und ausgeglichenere Hälften



mid=7

- Optimale Partionierung erreicht
 - 15 Elemente aufgespalten in zwei Partitionen mit je 7 Elementen
 - muss aber nicht immer so sein

Partition Methode



- teile den Bereich in zwei "alle kleiner" und "alle grösser" als Pivot
- gebe Index der Grenze zurück

```
public static int partition (int[] a, int left, int right) {
     int partition(int arr[], int left, int right) {
                                                          finde linkes Element
        int pivot = arr[(left + right) / 2];
                                                          grösser Pivot
        while (left <= right) {</pre>
                while (arr[left] < pivot) {</pre>
                        left++;
                                                          finde rechtes Element
                                                          kleiner Pivot
                while (arr[right] > pivot) {
                        right--;
                                                  schon gekreuzt?
                if (left <= right) {</pre>
                        swap(a,left,right);
                        left++;
                        right--;
        return left;
                                     index der neuen Grenze
```



die eigentliche Sort-Methode ist rekursiv:

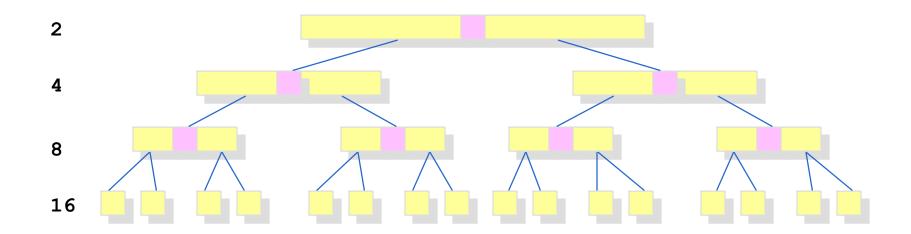
```
void quickSort(int[] a, int left, int right) {
    if (left < right) {
        int mid = partition (a, left, right);
        quickSort(arr, left, mid-1);
        quickSort(arr, mid , right);
    }
}

public void quickSort(int[] a){
    quickSort(a, 0, a.length-1);
}</pre>
```

Quicksort: Aufwand



- ein Bereich muss log₂(N) mal geteilt werden:
 - Es entsteht dabei ein binärer Partitionenbaum mit Tiefe log₂(N).
 - Der Aufwand, auf jeder Schicht diese komplett zu partitionieren, ist proportional zu N.
- der Gesamtaufwand ist somit proportional zu N×log₂(N).
- Die Ordnung von Quicksort ist somit O(N×log(N)),
 - wenn bei jeder Partitionierung eine gleichmässige Aufteilung der Daten erfolgt



Quicksort: Aufwand



- ungünstigster Fall:
 - jeder Partitionierungs-Schritt nur jeweils das Vergleichselement
 - -> Baum wird zu Kette (Liste) mit N Elementen:
 man sagt auch der Baum entartet oder degeneriert
- In diesem Fall ist der Aufwand proportional zu O(N²).
- Dies tritt jedoch nur in extra konstruierten Fällen auf
- Im Normalfall ist die Partitionierung bei Quicksort nahezu optimal

Quicksort immer die **erste Wahl**, wenn grössere Mengen von ungeordneten Daten sortiert werden müssen.

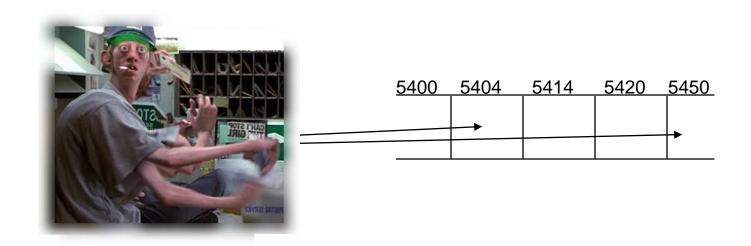


Distribution Sort

Distribution-Sort

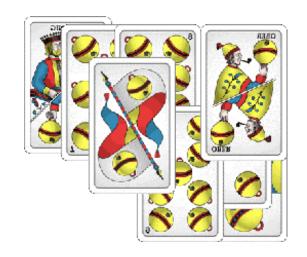


- Die bisher diskutierten Sortieralgorithmen basieren auf den Operationen:
 Vergleichen zweier Elemente und ev. Vertauschen zweier Elemente (swap).
- Im Gegensatz dazu kommt Distribution-Sort ohne Vergleiche aus.
- Die zu sortierenden Elemente werden
 - entsprechend dem Sortierschlüssel in Fächer verteilt: O(n)
 - zusammengetragen: O(n)
- Bsp: Briefe werden in die entsprechenden Fächer nach Plz. sortiert.



Distribution-Sort Beispiel







direktes Einfügen

















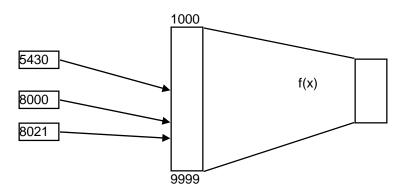




Distribution-Sort



Grundprinzip wie beim direkter Adressieren (vergl. Hashtable):



Vorteile

- schneller geht's nicht
- linearer Algorithmus: die Komplexität ist also O(N)

Nachteile

- Verfahren muss an den jeweiligen Sortierschlüssel angepasst werden.
- Geht nur bei Schlüsseln, die einen kleinen Wertebereich haben oder auf einen solchen abgebildet werden können, ohne dass die Ordnung verloren geht.
- Allgemeines Hashing funktioniert nicht: wieso?
- Distribution-Sort mit Abstand der schnellste Algorithmus zum Sortieren.
 - Es handelt aber nicht um ein allgemein anwendbares Sortierverfahren.



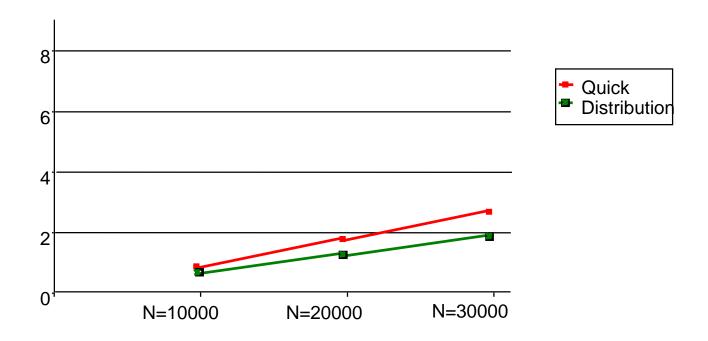
Laufzeitvergleich schneller Sortieralgorithmen

Laufzeitvergleich schneller Sortieralgorithmen



Laufzeitmessung bei zufällig sortierten Daten (in Sekunden):

	N = 10000	N = 20000	N = 30000	N=40000
Quick	1.57	3.38	5.21	7.19
Distribution	1.2	2.4	3.6	4.8



Vorsortierte Daten



☐ Bei vorsortierten Daten:

	N=10000	N=20000	N=30000	N=40000
Quick	0.48	1.02	1.43	2.16
Di stri buti on	1.2	2.4	3.6	4.8

- In der Praxis recht häufig
 - unsortierter Datenbestand wird einmalig eingebracht.
 - danach ändern sich in dem Datenbestand jeweils nur wenige Datensätze:
 - einige wenige Datensätze werden neu eingebracht.
 - einige wenige Datensätze werden geändert oder gelöscht.
- □ Es kann sich sogar lohnen, den Datenbestand auf die Sortiertheit vorab zu untersuchen (wird z.B. im JDK-Sort gemacht).
- -> Insertionsort verwenden

Übung



- Ein O(n*log n) Sortieralgorithmus brauche 1 Sekunde für 10'000 Elemente; wie lange braucht er für 100'000 Elemente?
 - es soll nur der erste Koeffizient betrachtet werden.

Optimalitätssatz für Sortieralgorithmen



Satz: Ein Sortieralgorithmus, der darauf beruht, dass Elemente **untereinander verglichen** werden, kann bestenfalls eine Komplexität von O(n×log(n)) im Worst Case haben.

- Distribution-Sort fällt nicht darunter, da er
 - nicht auf dem Vergleich von Elementen untereinander beruht.
 - auf Verteilen und Zusammentragen von Datensätzen mit Hilfe von Fächern basiert.



Externe Sortierverfahen

Externen Sortierverfahren: 2 Phasen Sortieren

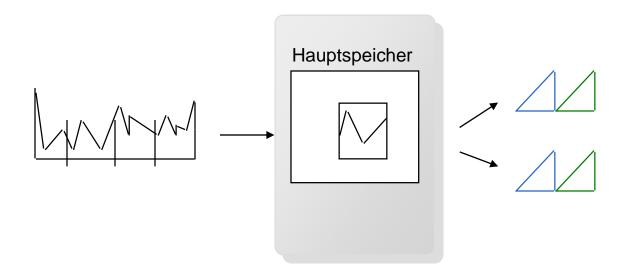


- Beim externen Sortieren liegen die Daten in einer Datei auf der Festplatte. Zwei Arten des Zugriffs sind möglich:
 - sequentieller Zugriff
 - der beliebige Zugriff auf die Element wäre zwar möglich, ergibt aber einen grossen Effizienzverlust (siehe Vorlesung BS)
- Annahmen:
 - Datenstrom der sequentiell gelesen wird
 - Jeweils nur ein Teil der Daten passt in den Hauptspeicher

1. Phase: Sortieren-Verteilen (Sort)



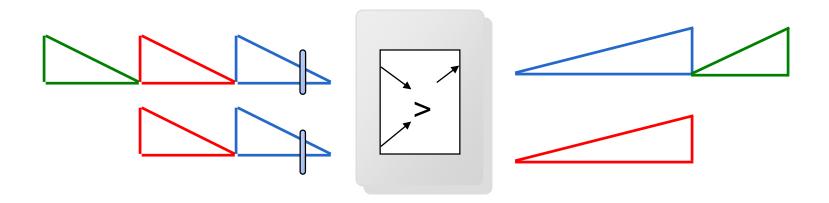
- Lade jeweils einen Teil der Datei in den Speicher
 - Sortiere diesen Teil mit schnellem internem Verfahren.
 - Schreibe sortiere Abschnitte in mehrere (mindestens zwei) Ausgabedateien
 - Es entstehen Folgen von sortierten Abschnitten in den Ausgabedateien



2. Phase: Mischen (Merge)



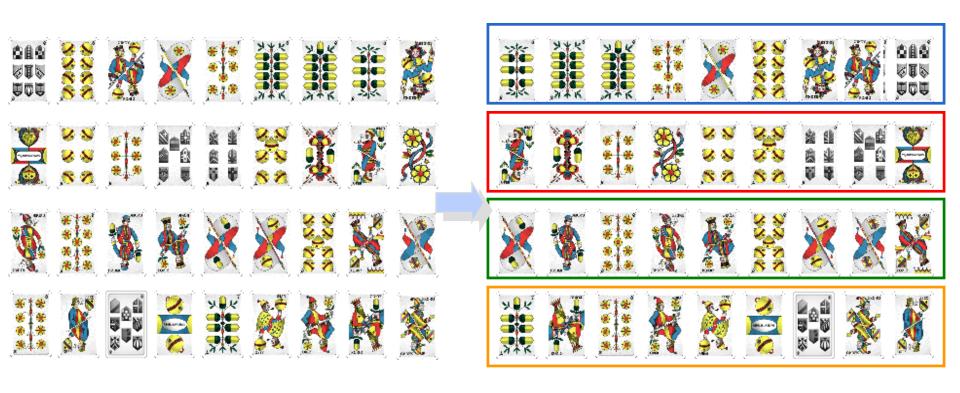
- 2. Phase: Mischen
 - Lese von beiden Dateien das erste Element
 - Schreibe das Kleinere und lese das Nächste von der gleichen Datei
- -> Länge der geordneten Abschnitte hat sich verdoppelt
 - ouput -> input
 - solange wiederholen, bis vollständig sortiert



Beispiel Jasskarten

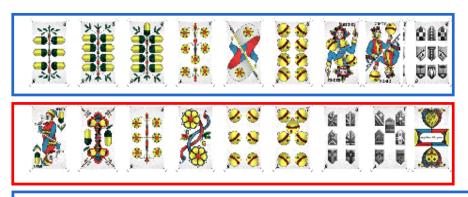


intern sortieren (nach Farbe und Punkte)



Misch Durchgang 1













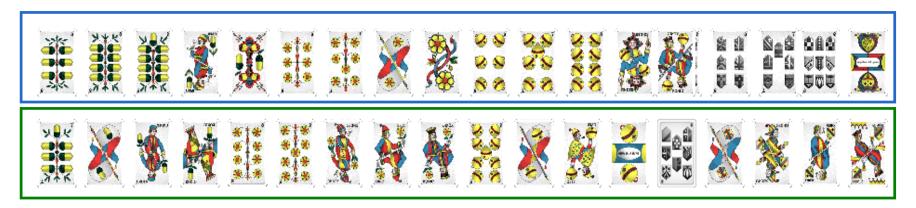
mischen



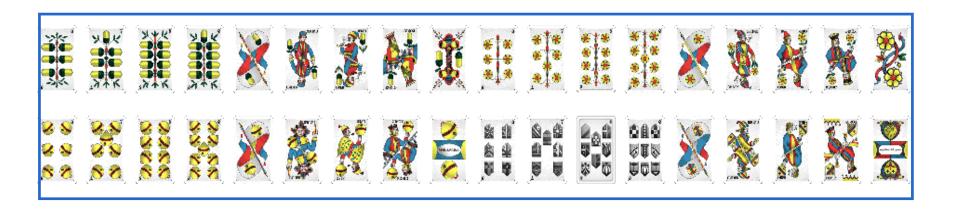


Misch Durchgang 2









Laufzeit



Annahme:

- Zeit für internes Sortieren kann vernachlässigt werden
- Beispiel: 16 Sequenzen (sortierte Abschnitte aus Sort-Phase), je 2 Eingabe-Dateien während Mischphase

1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
	<i>17</i> 18		19		20)	21		22		23		24		
	25 26					27				28					
	29						30								
31															

Generell, bei n Sequenzen und m Eingabedateien:

Aufwand Sortierphase: n

Aufwand je Mischphase: n

• Anzahl Mischphasen: $\lfloor \log_m n \rfloor$

• Gesamtaufwand Sortieren und Mischen: $n + n * \lfloor \log_m n \rfloor \Rightarrow O(n \log_m n)$





Internes oder externes Verfahren

- Sortieren im Hauptspeicher
- Sortieren im Hauptspeicher und Sekundärspeicher (Platte)

Methode des Algorithmus:

- Vertauschen
- Auswählen
- Einfügen
- Rekursion
- Verteilen
- Mehrphasen: Sortieren-Mischen



- Nach Effizienz:
 - Laufzeit: O(n²) oder O(n × log n) oder sogar O(n)
 - Speicherbedarf: Wieviel Speicher wird zusätzlich zu dem für die zu sortierenden Daten benötigt?
- Allgemein / mit speziellen Voraussetzungen:
 - allgemein: Benötigt nur Schlüsselvergleiche
 - allgemein: Ändern der Reihenfolge oder Angabe der Reihenfolge
 - allgemein: Wird die Reihenfolge von Datensätzen mit gleichem Sortierkriterium durch den Algorithmus geändert? →Stabilität
 - speziell: Der Algorithmus setzt eine bestimmte Struktur der Schlüssel voraus.



- Bibliotheksfunktion -> Collections.sort oder Arrays.sort
- wenige Datensätze (weniger als 1000),
 - Laufzeit unerheblich,
 - möglichst einfachen Sortieralgorithmus wählen (also Insertion-Sort, Selection-Sort oder Bubble-Sort).
- vorsortierte Datenbestände
 - dann Insertion- oder Bubble-Sort .
- viele ungeordnete Daten
 - dann Quicksort bevorzugen.
- viele Daten, ungeordnet, sehr oft zu sortieren
 - Distribution-Sort an das spezielle Problem angepasst
- sehr viele Daten
 - externes Sortierverfahren in Kombination mit schnellem Internem



Optimierung durch Kombination von Algorithmen

Optimierungen von Quicksort



- Quicksort ist schnell, aber wegen der Rekursion hat er einen relativ grossen initialen Aufwand: "Footprint"
- Für wenige (~10..100) zu sortierende Daten ist ein einfaches Sortierverfahren schneller
- Idee: ab einer bestimmten L\u00e4nge des Intervalls nicht mehr Quicksort verwenden, sondern z.B. InsertionSort; bringt ca.10%

```
static void quickerSort(int[] a, int left, int right) {
   if (right - left < QSTHREASHHOLD)
       insertionSort(a, left, right);
   else {
       int l = partition (a,left,right);
       quickerSort(arr, left, l-1);
       quickerSort(arr, l , right);
   }
}</pre>
```



Einschub Zufallszahlen

Einschub: Zufallszahlen



- Gleichverteilt: Jede Zahl innerhalb eines Intervalls kommt gleich häufig vor.
 Beispiel Zahlen eines Würfels
- Die Wahl der nächste Zahl einer Folge muss zufällig (ohne Bildungsgesetz) erfolgen.
- -> Es ist schwierig oder sogar unmöglich, echte Zufallszahlen auf einem Computern zu erzeugen
- echt zufällige physikalische Prozesse
 - Würfeln
 - radioaktiver Zerfall
 - Elektronen-Rauschen in einer Diode
 - Braunsche Bewegung
- echter Zufall in der Mathematik
 - nächste Zahl an einer beliebigen Stelle der Zahl PI
 - **3.1415926535897932384626433832795**

Einschub: Zufallszahlen



- Es werden Folgen von Zahlen erzeugt, die möglichst viele Eigenschaften von Zufallszahlen besitzen.
- Es wird eine Funktion bestimmt, bei der die Auswahl der nächsten Zahl scheinbar zufällig erfolgt: es kommt erst nach langer Zeit zu einer Wiederholung der Folge -> Pseudozufallszahlen

```
int z;
double random() {
    int a = 897; c = 2111; p = 123456;
    z = (a*z + c) % p;
    return z/p;
}
```

- gute Wahl von a,c und p ist schwierig; kann nur durch statische Analysen überprüft werden
- Nachteil: keine "echte" Zufallszahl
- Vorteil: es kann mehrmals die gleiche Folge erzeugt werden.
- in Java-Klasse Math: Math.random() für Bereich [0..1]
- für beliebigen anderen Bereich: r = (int)(k*Math.random())

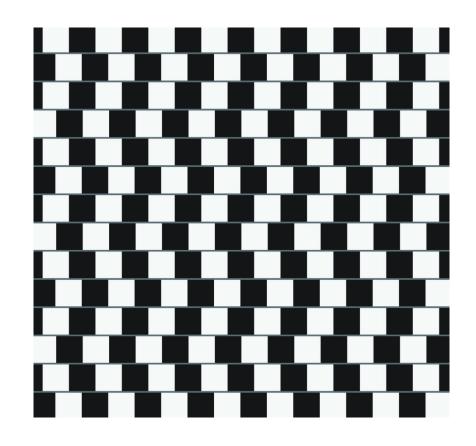
Einschub Zufallszahlen: Zufallszahlen mit Java



- Die Java-Klasse Random erlaubt grössere Flexibilität (als Math).
- Random(long seed)
 Erzeugt einen Zufallszahlengenerator. seed ist der Startwert für die erzeugten
 Zufallszahlen. Damit kann mehrmals die gleiche Zufallssequenz erzeugt werden.
- Random()
 Erzeugt einen Zufallszahlengenerator. Der Startwert wird aus der aktuellen aktuellen Tageszeit in Millisekunden bestimmt.
- nextInt(int n) liefert eine pseudozufällige, gleichverteilte Integer-Zahl im Bereich [o..n[
- nextDouble() liefert eine pseudozufällige, gleichverteilte Double-Zahl im Bereich [o..1[
- nextGaussian() liefert eine pseudozufällige, Gauss-verteilte Double-Zahl mit Mittelwert 0.0 und Standard-Abweichung 1.0.



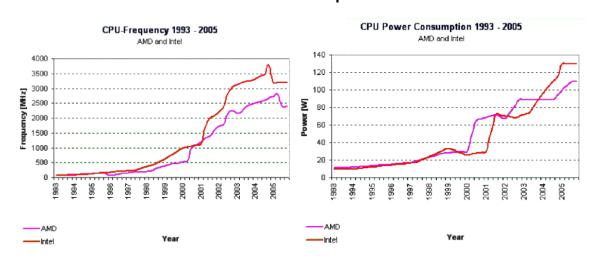
Optimierung durch Parallelisierung



Speed vs. Power Consumption



- Das grösste Problem heute ist die Wärmeabgabe der Chips
- Jeder CMOS Schaltvorgang braucht Energie, Verkleinerungen erhöht die Leckströme
- Die Energiedichte innerhalb einer CPU ist grösser als diejenige im Kern eines Kernreaktors
- Computer Industrie ist für 2% der weltweiten CO₂ Emissionen verantwortlich
- Rechenzentren: Stromkosten p.a. ~ HW Kosten





Beschleunigung durch Parallelisierung

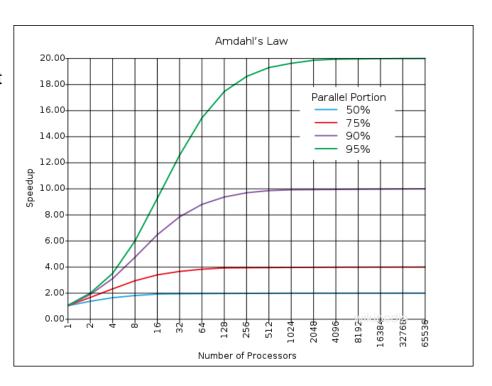


- Modern multicore CPUs sprechen eigentlich dafür aber
- Amdahl's Law
 - Die Geschwindigkeitssteigerung ist durch den sequentiellen Anteil im Programm limitiert

P: ist der Anteil des Programms, der parallelisiert werden kann

N: Zahl der Prozessoren

$$Speedup = \frac{1}{(1-P) + \frac{P}{N}}$$



Es kommt aber noch ein Overhead durch die Steuerung der Threads

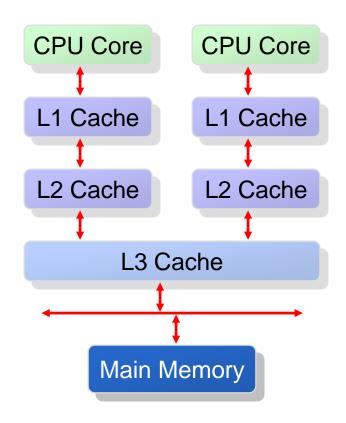
Zugriff auf den Hauptspeicher



Zugriffszeiten

register: < 1 clk
L1: ~ 4 clks
L2: ~ 11 clks
L3: ~ 40 clks
main memory: ~150-300 clks

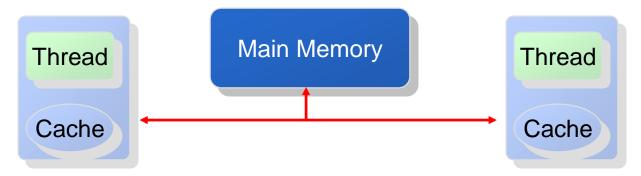
 Hauptspeicherzugriff ist im Vergleich zum Cache sehr teuer



Java Memory Modell



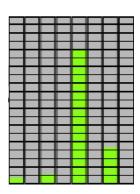
- JMM abstrahiert von physikalischem Memory Modell
- Alle Threads teilen Hauptspeicher
- Jeder Thread hat einen lokalen Arbeitsspeicher
- Veränderungen aus lokalem (Thread-) Arbeitsspeicher werden zurückgeschrieben
 - Bei expliziter Synchronisation
 - Thread Start und Beendigung
 - Lesen/Schreiben von volatiles
 - Erstes Lesen von finals



Prozessor Auslastung



Single Threaded



Multithreaded

```
■ MergeSortLab (1) [Java Application]

■ MergeSortLab at localhost:60641

■ Thread [main] (Suspended)

■ MergeSortLab.main(String[]) line: 53

■ Daemon Thread [ForkJoinPool-1-worker-6] (Running)

■ Daemon Thread [ForkJoinPool-1-worker-7] (Running)

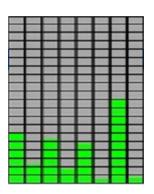
■ Daemon Thread [ForkJoinPool-1-worker-1] (Running)

■ Daemon Thread [ForkJoinPool-1-worker-3] (Running)

■ Daemon Thread [ForkJoinPool-1-worker-8] (Running)

■ Daemon Thread [ForkJoinPool-1-worker-5] (Running)

■ Daemon Thread [ForkJoinPool-1-worker-4] (Running)
```



NaiveParallelQuicksort

Als separater Thread



private int[] a; private int left; private int right;

```
class NaiveParallelQuicksort extends Thread {
                                                                            Setzen der
      public NaiveParallelQuicksort(int[] a, int left, int right) {
                                                                            Parameter
         this.a = a; ...
     public static void sort(int[] a) {
         Thread root = new Thread(new NaiveParallelQuicksort(a, 0, a.length - 1));
         root.start();
         root.join();
      public void run() {
                                                          Parallele Threads
         int l = 0;
                                                          starten
         Thread t1 = null;
         Thread t2 = null;
         if (left < right) {</pre>
              l = partition(a, left, right);
             t1 = new NaiveParallelQuicksort(a, left, l-1);
             t1.start();
             t2 = new NaiveParallelQuicksort(a, 1 , right);
             t2.start();
                                               Warte bis
              if (t1 != null) t1.join();
                                               beendet
              if (t2 != null) t2.join();
```

Ein neuer Thread pro Task



- Je ein neuer Thread für jede Partitionsaufgabe
- Java Threads werden auf Betriebssystems Threads abgebildet: "Kernel Level Threads"

Vorteile

- Die Rechenzeitzuteilung kann besser (von BS) verwaltet werden
- Sind mehrere CPU-Kerne/Proz. im Rechner vorhanden, können diese ausgenutzt werden.

Aber

- Erzeugung und Zerstörung von Threads kostet (viel) Zeit
- Instanziierte Threads belegen Speicher
- Ineffektiv, mehr Threads zu erzeugen, als die Prozessoren gleichzeitig handhaben können, da immer einige inaktiv (idle) sein werden

NaiveParallelQuicksort erste Korrektur



```
class NaiveParallelQuicksort extends Thread {
      private final int SPLIT THRESHOLD = 100000;
     public void run() {
         int 1 = 0;
         Thread t1 = null;
         Thread t2 = null;
                                                                   Nur wenn Task
         if (left < right) {</pre>
                                                                   genügend gross
               l = partition(a, left, right);
                                                                   parallel ausführen
               if (1 - left > SPLIT_THRESHOLD) {
                  t1 = new NaiveParallelQuicksort(a, left, l-1);
                  t1.start();
                                                               Sonst sequentiell
              } else {
                   Quicksort.sort(a, left, l-1);
              if (right - 1 > SPLIT_THRESHOLD) {
                  t2 = new NaiveParallelQuicksort(a, 1 , right);
                  t2.start();
              } else {
                   Quicksort.sort(a, l , right);
              if (t1 != null) t1.join();
              if (t2 != null) t2.join();
}
```



Threadpools

Idee der Thread Pools

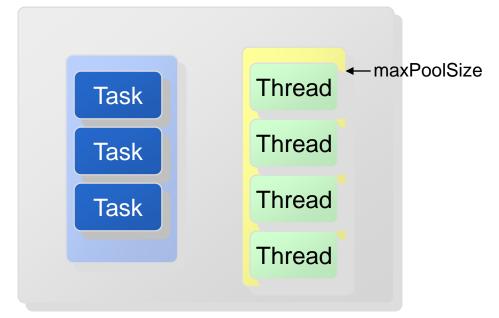


- Es wird einer gewissen Anzahl von einmal gestarteten Threads (Pool von Threads) immer wieder eine neue Aufgabe (Tasks) übergeben.
- Pool Size entspricht in etwa der Anzahl Rechnerkerne
 - bei I/O intensiven Threads mehr, da immer ein Teil wartend/blockiert ist

java.lang.Runtime.getRuntime().availableProcessors()

Die Reihenfolge der Abarbeitung der Tasks wird durch eine Ausführungs-

strategie bestimmt



Ausführungsstrategien

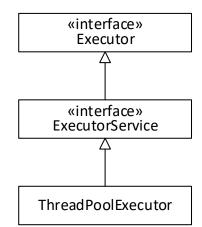


- bessere Kontrolle über Ressourcen durch Einhaltung einer Ausführungsstrategie
 - in welchem Thread wird ein Task ausgeführt
 - in welcher Reihenfolge werden die Tasks ausgeführt (LIFO, FIFO, priorisiert, ...)
 - Anzahl der Tasks die gleichzeitig ausgeführt werden dürfen
 - Anzahl der Tasks die auf Ausführung warten dürfen
- Mögliche Ausführungsstrategien:
 - Begrenzung der Thread-Anzahl
 - Caching von Threads
 - Queueing von Tasks
- Auswahl effektivster Policy hängt vom Anwendungsfall ab

Java Implementation



- Interface Executor (java.util.concurrency) stellt Framework zur Thread-Ausführung bereit, das verschiedene Ausführungsstrategien realisiert
- Interface ExecutorService für ThreadPools
- verschiedene Varianten des ThreadPoolExcutors werden durch Factory-Methoden der Klasse Executors bereitgestellt:



- FixedThreadPool, (public static ExecutorService newFixedThreadPool(int nThreads))
 Pool mit fester Menge von Threads, die zur Ausführung eingereichter Tasks eingesetzt werden
- CachedThreadPool, (public static ExecutorService newCachedThreadPool()):
 Pool mit flexibler Menge von Threads, die sich an die Zahl der eingereichten Tasks anpasst
- SingleThreadExecutor, (public static ExecutorService newSingleThreadExecutor()): einzelner Thread, der eingereichte Tasks nacheinander (gemäß FIFO- oder LIFO-Prinzip oder nach Priorität) abarbeitet
- ScheduledThreadPool, (public static ScheduledExecutorService newScheduledThreadPool(int corePoolSize)):
 Pool mit fester Menge von Threads, die zur zeitgesteuerten bzw. wiederkehrenden Ausführung eingereichter Tasks eingesetzt werden
- Und andere...

Lebenszyklus des Threadpools



Erzeugung via Fabrikmuster Methoden

```
threadPool = Executors.newFixedThreadPool(parallelism);
```

- Drei Zustände:
 - 1. running
 - Threadpool nimmt Tasks entgegen und führt sie aus, sobald Threads verfügbar sind
 - 2. shutting down Varianten:

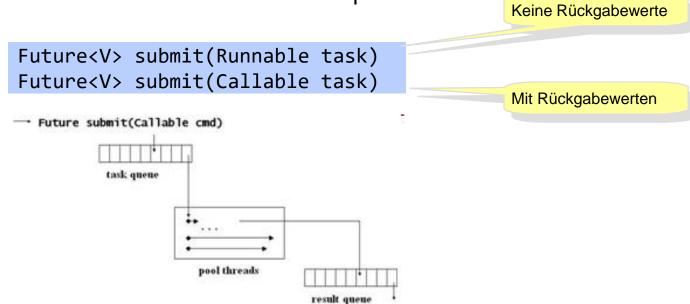
```
threadPool.shutdown();
```

- graceful shutdown
- Threadpool führt laufende und bereits angenommene, aber nicht begonnene Tasks noch aus, nimmt jedoch keine neuen Tasks mehr an
- abrupt shutdown
- Threadpool führt laufende Tasks noch aus, verwirft aber bereits angenommene, noch nicht laufende Tasks, und nimmt keine neuen Tasks mehr an
- 3. terminated
 - keine Tasks werden mehr ausgeführt oder angenommen

Einstellen eines Threads



Einstellen eines Tasks in einen Threadpool



- Verwendung von Callable-Interface wenn Rückgabewerte/Resultate benötigt werden (Runnable liefert NULL-Wert bei Erfolg)
- Ein Future (Interface) stellt das Ergebnis einer asynchronen Berechnung dar

Resultat der Ausführung



- Submit des Runnable (oder Callable) in Threadpool liefert Future
 - mit get-Methode zur Abfrage des Rückgabewerts vom Typ v
 - wartet, bis Rückgabewert feststeht
 - ggf. nur solange, bis angegebener Timeout erreicht
 - mit cancel-Methode zur Stornierung der Aufgabe
 - unmittelbare Streichung, wenn Bearbeitung noch nicht begonnen
 - Abbruchversuch, wenn schon in Bearbeitung

Tasks mit Rückgabewerten



Realisierung der Anwendungslogik mit Rückgabetyp V in der Methode call einer Implementierung des Interfaces Callable statt Runnable:

```
public interface Callable<V> {
      V call() throws Exception;
}
```

Beispiel:

```
class Foo implements Callable<Integer> {
    ...
    public Integer call() {
        int result = ...;

        return result;
    }
}
```

Thread Safe Collections



- im Paket java.util.concurrent gibt es einige Thread Safe Collections
- Im Fall von erwarteten Race Conditions (oder ähnlichem) sollten diese verwendet werden

ConcurrentHashMap <k,v></k,v>	<pre>// A hash table supporting full concurrency of retrievals and adjustable expected concurrency for updates</pre>
ConcurrentLinkedQueue <e></e>	<pre>// An unbounded thread-safe queue based on linked nodes.</pre>
SynchronousQueue <e></e>	<pre>// A blocking queue in which each put must wait for a take, and vice versa.</pre>

Beispiel QuicksortTask



```
public class QuicksortTask implements Runnable {
     static ExecutorService threadPool;
                                                                                    Initialisiere Threadpool
     static ConcurrentLinkedQueue<Future> futureList;
      public void sort(int[] a) {
         int parallelism = java.lang.Runtime.getRuntime().availableProcessors()*2;
         threadPool = Executors.newFixedThreadPool(parallelism);
         futureList = new ConcurrentLinkedQueue<Future>();
         QuicksortTask rootTask = new QuicksortTask(a, 0, a.length - 1);
         futureList.add(threadPool.submit(rootTask));
                                                                                  starte ersten Task
         while (!futureList.isEmpty()) {
                                             warte auf Beendigung
              futureList.poll().get();
                                             aller Tasks
         threadPool.shutdown():
                                     Terminiere Threadpool
      public void run() {
         int l = 0;
                                                                                füge neuen Task in
         if (left < right) {</pre>
                                                                                Threadpool
              1 = partition(a, left, right);
              if (1 - left > SPLIT THRESHOLD) {
                  futureList.add(threadPool.submit(new QuicksortTask(a, left, 1-1)));
```



Fork Join

Fork/Join



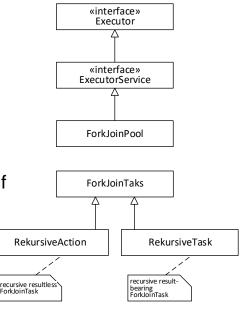
- Neues Framework für die parallele Ausführung ab Java 7
- Macht grundsätzlich dasselbe wie Threadpools
- Threads manchmal immer noch zu schwergewichtig
- "Teile und Herrsche" Prinzip auf Parallelität angewandt

```
Result solve(Problem problem) {
  if (problem is small)
    directly solve problem
  else {
    split problem into independent parts
    fork new subtasks to solve each part
    join all subtasks
    compose result from subresults
  }
}
```

So wird es gemacht



- Definiere ein ForkJoinPool-"thread-manager"-Object
- Definiere ein Task-Object das von der Klasse RecursiveTask erbt
 - Kann generisch sein, wenn Rückgabewerte vorhanden sind.
 - Instanziere den ForkJoinPool
 - Instanziere (Haupt-)Task Objekt und rufe fjpool.invoke (task) auf
- In der compute-Methode (innerhalb Task-Object)
 - Code mit der Aufteilung des Problems
 - Löse Problem direkt falls klein/einfach genug
 - Sonst teile Problem auf:
 - rufe invokeAll(task1, task2, ...). dieses wartet bis alle beendet oder
 - starte task fork () auf dem ersten und invoke() mit dem zweiten mit anschliessendem join()



Threads vs. Fork/Join



Threads	Fork/Join
Do subclass Thread Do override run Do call start Do call join (je Thread)	Do subclass RecursiveTask <v> Do override compute Do call invoke, invokeAll, fork Do call join which returns answer or Do call invokeAll on multiple tasks</v>

Beispiel QuicksortForkJoin - invokeAll



```
public class QuicksortForkJoin extends RecursiveAction {
     public static void sort(int[] a) {
         int parallelism = java.lang.Runtime.getRuntime().availableProcessors()*2;
         forkJoinPool = new ForkJoinPool(parallelism);
         QuicksortForkJoin rootTask = new QuicksortForkJoin(a, 0,a.length - 1);
         forkJoinPool.invoke(rootTask);
                                                    übergebe Task FJ Queue und
     public void compute() {
                                                    warte auf Terminierung
         int l = 0;
         if (left < right) {</pre>
             l = partition(a, left, right);
              ForkJoinTask t1 = null, t2 = null;
             if (1 - left > SPLIT THRESHOLD && right - 1 > SPLIT THRESHOLD) {
                  t1 = new QuicksortForkJoin(a, left, l-1);
                  t2 = new QuicksortForkJoin(a, 1 , right);
                  invokeAll(t1, t2);
             } else {
                                                                     übergebe FJ Queue und warte
                  Quicksort.sort(a, left, l-1);
                                                                     auf Terminierung
                  Quicksort.sort(a, 1, right);
```

Beispiel QuicksortForkJoin - fork/invoke/join



```
public class QuicksortForkJoin extends RecursiveAction {
     public static void sort(int[] a) {
         int parallelism = java.lang.Runtime.getRuntime().availableProcessors();
         forkJoinPool = new ForkJoinPool(parallelism);
         QuicksortForkJoin rootTask = new QuicksortForkJoin(a, 0,a.length - 1);
         forkJoinPool.invoke(rootTask);
                                                    übergebe Task FJ Queue und
     public void compute() {
                                                    warte auf Terminierung
         int l = 0;
         if (left < right) {</pre>
             l = partition(a, left, right);
             ForkJoinTask t1 = null;
             if (1 - left > SPLIT THRESHOLD) {
                  t1 = new QuicksortForkJoin(a, left, l-1).fork();
             } else Quicksort.sort(a, left, l-1);
             if (right - 1 > SPLIT_THRESHOLD) {
                  new QuicksortForkJoin(a, l , right).invoke();
             } else Quicksort.sort(a, l , right);
             if (t1 != null) {
                  t1.join();
     }
```

Zusammenfassung



- Teile und Herrsche Prinzip
- Quicksort
 - Partitionierung
 - Wahl des Pivots
 - Sequentielle Optimierungen
- Optimierung durch Parallelisierung
 - Naive
 - Threads
 - Threadpools
 - Fork/Join

Anhang: Lösung Funktional



Java 8 Streams:

```
import java.util.*
public class Main {
     private static Function<Integer, Predicate<Integer>> smallerThan = x -> y -> y < x;</pre>
     public static List<Integer> qsort(List<Integer> 1){
         if(l.isEmpty()) return new ArrayList<>();
         return Stream.concat(Stream.concat(
              qsort(l.stream().skip(1).filter(smallerThan.apply(l.get(0)))
                  .collect(Collectors.toList())).stream(),
              Stream.of(1.get(0))),
              qsort(1.stream().skip(1).filter(smallerThan.apply(1.get(0)).negate())
                  .collect(Collectors.toList())).stream()).collect(Collectors.toList());
     public static void main(String[] args) {
         List<Integer> 1 = Arrays.asList(5,6,7,23,4,5645,6,1223,44453,60182,2836,23993, 1);
         System.out.println(qsort(1));
```

Haskell:

```
qsort [] = []
qsort (x:xs) = qsort (filter (< x) xs) ++ [x] ++ qsort (filter (>= x) xs)
```