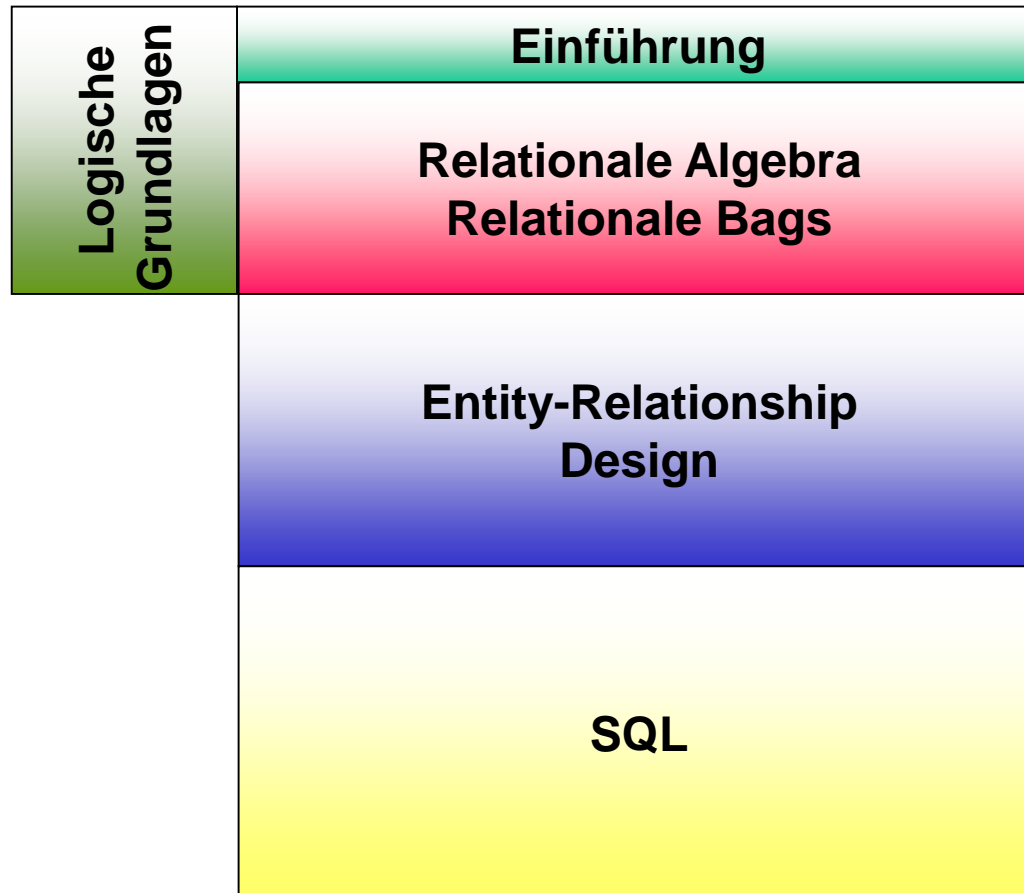


# DAB1 – Datenbanken 1

Dr. Daniel Aebi (aebd@zhaw.ch)

## Lektion 2: Relationenmodell, relationale Algebra

# Wo stehen wir?



← "You are here"

Diskutiert im Unterricht. Machen Sie Ihre eigenen Notizen.

# Lernziele Lektion 2

- Bedeutung relationaler Datenbanken für die Praxis kennen.
- Ursprung des relationalen Modelles kennen.
- Begriffe kennen: Relation, Tupel, Attribut, Wertebereich.
- Erste Grundoperationen auf Relationen verstehen.

# Datenbanksysteme – Entwicklung

- Ganz verschiedene Datenmodelle & Technologien im Einsatz:
  - Hierarchisch (ab 70er Jahre, z.B. IMS von IBM)
  - Netzwerk (ab 70er Jahre, z.B. IDMS von CA, UDS von Siemens)
  - **Relational** (ab 80er Jahre)
  - Objekt-Relational
  - Objektorientiert
  - Logikbasiert
  - Deduktiv
  - XML
  - NoSQL
  - ...

# Begriff: Strukturierte Daten

- Daten, die eine reguläre, **fest vorgegebene Struktur** besitzen. Mehrere «gleichartige Datensätze» mit identischem Aufbau. Gut «tabellarisch» darstellbar.

Synonym: formatierte Daten.

- Beispiel:

Name	Letz.	Veränderung	Hoch	Tief	Volumen
<b>SMI PR</b>	9'220.69	▼ -70.23 (-0.76 %)	9'272.50	9'220.69	-
Trade <b>ABB LTD N</b>	25.67	▼ -0.36 (-1.38 %)	26.03	25.67	4'970'180
Trade <b>ADECCO N</b>	75.30	▼ -1.08 (-1.41 %)	76.24	75.30	911'282
Trade <b>CS GROUP N</b>	18.06	▼ -0.18 (-0.99 %)	18.22	17.955	8'142'755
Trade <b>GEBERIT N</b>	435.60	▼ -3.90 (-0.89 %)	438.80	435.10	113'461
Trade <b>GIVAUDAN N</b>	2'179.00	▼ -35.00 (-1.58 %)	2'216.00	2'178.00	35'706
Trade <b>JULIUS BAER N</b>	63.58	▼ -0.80 (-1.24 %)	64.50	63.48	1'047'244
Trade <b>LAFARGEHOLCIM N</b>	56.28	▼ -0.92 (-1.61 %)	57.30	56.28	2'152'747
Trade <b>LONZA N</b>	251.60	▼ -0.40 (-0.16 %)	252.40	248.60	631'566
Trade <b>NESTLE N</b>	79.42	▼ -1.00 (-1.24 %)	80.14	79.10	6'063'516
Trade <b>NOVARTIS N</b>	82.64	▼ -0.88 (-1.05 %)	83.56	82.40	4'875'390
Trade <b>RICHEMONT N</b>	88.78	▼ -1.14 (-1.27 %)	89.60	88.68	1'356'277
Trade <b>ROCHE GS</b>	224.15	▲ 1.05 (0.47 %)	226.00	221.15	2'780'105
Trade <b>SGS N</b>	2'469.00	▼ -29.00 (-1.16 %)	2'494.00	2'468.00	13'304
Trade <b>SIKA I</b>	7'820.00	▼ -180.00 (-2.25 %)	8'010.00	7'820.00	8'814
Trade <b>SWATCH GROUP I</b>	417.20	▼ -10.00 (-2.34 %)	426.50	417.20	211'735
Trade <b>SWISS LIFE HOLDING AG N</b>	351.20	▼ -1.10 (-0.31 %)	352.40	348.60	146'636
Trade <b>SWISS RE N</b>	92.22	▲ 0.52 (0.57 %)	92.92	90.90	2'298'221
Trade <b>SWISSCOM N</b>	506.80	▼ -1.00 (-0.20 %)	508.80	504.00	188'734
Trade <b>UBS GROUP N</b>	18.94	▼ -0.115 (-0.60 %)	19.145	18.93	8'793'161
Trade <b>ZURICH INSURANCE N</b>	307.80	▲ 0.30 (0.10 %)	308.90	306.60	379'067

# Begriff: Unstrukturierte Daten


- Daten, für deren Elemente keine bestimmte Anordnung bzw. Struktur vorgeschrieben ist. Sie haben also **keine explizite Struktur** (aber ev. eine implizite, z.B. Grammatikregeln für Text).

Synonyme: unformatierte oder formatfreie Daten.

- Beispiele:
  - Texte (können auch strukturiert sein, z.B. gewisse Formulare)
  - Bilder
  - Filme
  - Audiodaten
  - ...

# Begriff: Semi-strukturierte Daten

- Daten, die **teilweise irreguläre bzw. unvollständige Strukturen** aufweisen, die sich öfters ändern können. Das Schema kann evtl. aus zusätzlicher Information (sog. „markup“) (re)konstruiert werden.
- Beispiel:



## Web

[OSZ Handel 1 Datenbanksysteme Relationale Datenbanken im ...](#)

Unterrichtsmaterial Relationale Datenbanken Datenbanken **Datenbanksysteme**.  
[oszhdl.be.schule.de/gymnasium/faecher/informatik/datenbanken/index.htm](#) - 19k -  
[Im Cache](#) - [Ähnliche Seiten](#)

[Amazon.de: Datenbanksysteme. Eine Einführung.: Bücher](#)

**Datenbanksysteme**. Eine Einführung., Alfons Kemper, Andre Eickler.  
[www.amazon.de/exec/obidos/ASIN/3486273922](#) - 37k - [Im Cache](#) - [Ähnliche Seiten](#)

[Amazon.de: Datenbanksysteme. Konzepte und Techniken der ...](#)

**Datenbanksysteme**. Konzepte und Techniken der Implementierung., Theo Härder, Erhard Rahm.

[www.amazon.de/exec/obidos/ASIN/3540421335](#) - 48k - [Im Cache](#) - [Ähnliche Seiten](#)

[ [Weitere Ergebnisse von www.amazon.de](#) ]

[PDF] [Datenbanksysteme](#)

Dateiformat: PDF/Adobe Acrobat

**Datenbanksysteme** (basierend auf der Auswertung von Tabellen) sind inzwischen ...

**Datenbanksysteme**, die auf dem hierarchischen Datenmodell basieren, ...

[www.igg.tu-berlin.de/fileadmin/Daten\\_FGA/GIS1/skript.pdf](#) - [Ähnliche Seiten](#)

[Datenbanksystem - Wikipedia](#)

Die relationalen **Datenbanksysteme** verdrängen in den 1980ern die hierarchischen und netzwerkartigen Systeme und der Großteil der Behörden, Konzerne, ...

[de.wikipedia.org/wiki/Datenbank](#) - 39k - [Im Cache](#) - [Ähnliche Seiten](#)

Von Stockinger Kurt (stog) <stog@zhaw.ch> ★

Betreff: Re: AW: AW: Virtuelle Maschine für DB + DWH Modul (CAS Information Engineering)

An Looser Jonas (losj) <losj@zhaw.ch> ★, Aebi Daniel (aebd) <aebd@zhaw.ch> ★

Kopie (CC) Brossi Pietro (brpi) <brpi@zhaw.ch> ☆

Danke, Jonas

@Pietro, kannst Du bitte die Maschine 11 klonen, sodass wir insgesamt 12 VMs haben?

Merci,  
Kurt

--

Dr. Kurt Stockinger

Associate Professor of Computer Science (Dozent)

Zurich University of Applied Sciences - ZHAW

Obere Kirchgasse 2, P.O. Box

CH-8401 Winterthur, Switzerland

Email: [Kurt.Stockinger@zhaw.ch](mailto:Kurt.Stockinger@zhaw.ch) | Tel: +41 58 934 49 79 | <http://www.dlab.zhaw.ch>



# Datenarten ↔ Technologien

- Unterschiedliche Datenarten verlangen nach unterschiedlichen Technologien:
  - Strukturierte Daten: **Relationale Datenbanken**
  - Semi-Strukturierte Daten: **XML, JSON, ...**
  - Unstrukturierte Daten: **???** (diverse proprietäre Technologien)

# Relationale Datenbanken

- **Relationale Datenbanken** sind hervorragend geeignet um **strukturierte Daten** zu verwalten. Technologie und Produkte haben sich über Jahrzehnte entwickelt, sind entsprechend leistungsfähig und ausgereift. Für **semi-strukturierte** Daten eignen sich vor allem **XML-Technologien**.
- Relationale Datenbanken sind – trotz Schwächen bei der Verwaltung von semi-strukturierten und unstrukturierten Daten – heute immer noch die weitaus **wichtigste Datenbanktechnologie**.
- Die Entwicklung der letzten paar Jahre geht in Richtung "Ausbau" der relationalen Technologie (aber Achtung: meist ohne mathematisch saubere Grundlage):
  - Erweiterungen für XML-Daten, "OO", BI, ...
  - Skalierung (horizontal, vertikal) → "big data"

# Relationale Datenbanken

- Verbreitung von relationalen Datenbankverwaltungssystemen:

## DB-Engines Ranking

Das DB-Engines Ranking ist eine Rangliste der Popularität von Datenbankmanagementsystemen. Die Rangliste wird monatlich aktualisiert.

Lesen Sie mehr über die [Berechnungsmethode](#) der Bewertungen.



Trend-Diagramm

345 Systeme im Ranking, September 2018


Rang			DBMS	Datenbankmodell	Punkte		
Sep 2018	Aug 2018	Sep 2017			Sep 2018	Aug 2018	Sep 2017
1.	1.	1.	Oracle +	Relational DBMS	1309,12	-2,91	-49,97
2.	2.	2.	MySQL +	Relational DBMS	1180,48	-26,33	-132,13
3.	3.	3.	Microsoft SQL Server +	Relational DBMS	1051,28	-21,37	-161,26
4.	4.	4.	PostgreSQL +	Relational DBMS	406,43	-11,07	+34,07
5.	5.	5.	MongoDB +	Document Store	358,79	+7,81	+26,06
6.	6.	6.	DB2 +	Relational DBMS	181,06	-0,78	-17,28
7.	↑ 8.	↑ 10.	Elasticsearch +	Suchmaschine	142,61	+4,49	+22,61
8.	↓ 7.	↑ 9.	Redis +	Key-Value Store	140,94	+2,37	+20,54
9.	9.	↓ 7.	Microsoft Access	Relational DBMS	133,39	+4,30	+4,58
10.	10.	↓ 8.	Cassandra +	Wide Column Store	119,55	-0,02	-6,65

# Gründe für den Erfolg des rel. Modelles

- Einfache Datenstruktur: **Relation**
- **Mengenorientierte** Verarbeitung der Daten, alle Operationen führen wieder zu Relationen. **Wenige Grundoperationen** zur Verarbeitung und dadurch eine klare Semantik ( $\rightarrow$  relationale Algebra).
- **Formale Theorie** zur Modellierung und Anfrageverarbeitung.
- Implementationen sind relativ einfach zu benutzen:
  - DDL (data definition language): SQL
  - DML (data manipulation language): SQL
  - DQL (data query language): SQL

# Wer hats erfunden?

- E. F. Codd: A Relational Model of Data for Large Shared Data Banks. Comm. of the ACM, 13(6): 377-387(1970)



- Codd hat dafür den bedeutendsten Preis in der Informatik gewonnen. Welchen?
- In der Praxis (als formale Grundlage von RDBMS) von sehr grosser Bedeutung!

# Begriff: Wertebereich (Domäne)

- Menge einfacher bzw. „atomarer“ Werte (entspricht im wesentlichen einem unstrukturierten **Datentyp** einer höheren Programmiersprache).
- Beispiele:
  - Ganze Zahlen, Fixpunktzahlen (Dezimalbrüche), Gleitkommazahlen, ...
  - Menge aller Zeichenketten, evt. einer festen Länge
  - Aufzählungstypen, z.B. {red, green, blue}, {CHF, EUR, GBP, USD}
  - Unterbereichstypen, z.B. ganze Zahlen im Intervall [100 ... 999]
  - ...

# Begriff: Attribut

- «Eigenschaften, die uns interessieren» (siehe später: ERM)
- Ein Attribut besteht aus zwei Teilen:
  - Bezeichnung/Name
  - Domäne/Wertebereich, aus der die zugehörigen Werte stammen können
- Bsp:
  - Anrede, {„Herr“, „Frau“}
  - Ort, string[30]
  - Gehalt, float
  - ...

# Begriff: Tupel (n-Tupel)

- Sammlung von als zusammengehörig betrachteter Attribute:
  - Feste Zahl von Komponenten
  - Beliebige Anordnung (d.h. Reihenfolge ist erst wichtig, wenn einmal festgelegt)
  - Der Attributwert entstammt einer für jedes Attribut festgelegten Domäne
- Wichtig: Die Attributwerte verändern sich über die Zeit, die Attribute selbst, also Name, Bedeutung und Wertebereich, bleiben konstant
- Eine Menge von gleichartig strukturierten Tupeln bilden eine Relation:

Wert des Attributs  $A_i$  des Tupels  $t$

R				
$A_1$	...	$A_i$	...	$A_n$
$a_{11}$	...	...	...	$a_{1n}$
...	...	...	...	...
$a_{k1}$	...	$a_{ki} = t.A_i$	...	$a_{kn}$
...	...	...	...	...

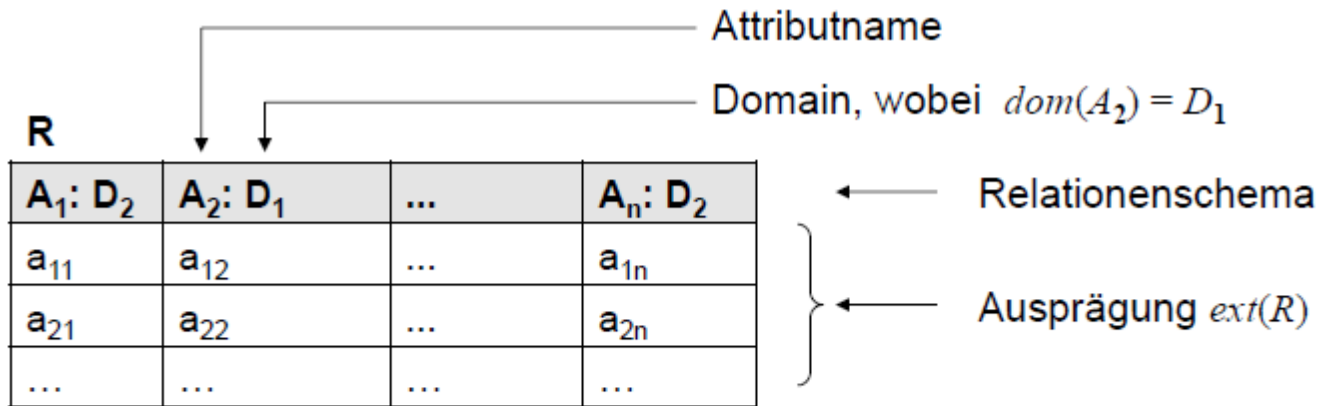
← Tupel  $t$



# Begriff: Relation

- Eine Relation  $R$  besteht aus zwei Teilen, einem:
  1. Einem sogenannten **Relationenformat (Heading, Schema, Relationsvariable)**: Menge von Namen von Attributen  $\{A_1, \dots, A_n\}$ , wobei jedem Attributnamen  $A_i$  ein Domain (Wertebereich)  $\text{dom}(A_i) \in \{D_1, \dots, D_m\}$  zugeordnet wird  
  
und
  2. Einer sogenannten **Ausprägung** (Menge von Tupeln, die dem Relationenschema entsprechen):  $\text{ext}(R) \subseteq \text{dom}(A_1) \times \dots \times \text{dom}(A_n)$
- Etwas zum Aufschneiden: «Eine Relation ist eine Teilmenge des kartesischen Produktes von  $n$  Wertebereichen»
- Wichtig: Relationen sind **Mengen**, enthalten also (per Definition) **keine doppelten Elemente!!**

# Begriff: Relation (Notationen)



Gleiche Relation ohne Angabe der Domains:

**R**

$A_1$	$A_2$	...	$A_n$
$a_{11}$	$a_{12}$	...	$a_{1n}$
$a_{21}$	$a_{22}$	...	$a_{2n}$
...	...	...	...

Kurznotation für Relationenschema:  $R(A_1, A_2, \dots, A_n)$

# Beispiel: Relation

## Employees

EmpNo: EmpNos	Name: PersonNames	AdrCity: CityNames	YrSalAmt: INTEGER	YrSalCur: Currencies	YrBonAmt: INTEGER	YrBonCur: Currencies
1	'Bechtolsheim'	'Palo Alto'	100000	'USD'	50000	'USD'
2	'Khosla'	'Altos Hills'	200000	'USD'	100000	'USD'
3	'McNealy'	'Atherton'	150000	'USD'	200000	'USD'
5678	'Saaner'	'Thalwil'	120000	'CHF'	100000	'CHF'

© R.Marti, 2004

- Domänen:
  - EmpNos = INTEGER
  - PersonNames = VARCHAR(30)
  - CityNames = VARCHAR(30)
  - Currencies = {'USD', 'GBP', 'EUR', 'CHF'}

# Relationenformat

- Relationen gehen im Laufe der Zeit in andere Relationen über. Aber: zeitlich konstant an den Beispielrelationen ist das gemeinsame **Format**.
- Wir nennen dieses Format **Relationenformat** und schreiben (z.B.):

Studenttyp(StudentName, DateOfBirth, StudentsFee)

- In der Literatur wird oft auch die Bezeichnung Relationenschema oder Relationsvariable verwendet
- Die Komponenten des Relationenformats sind Attribute, im Beispiel: StudentName, DateOfBirth und StudentsFee

# Bemerkung zu Domänen

- Zweck von Domänen
  - Theorie: Nur Attribute mit gleichen Domänen sind „kompatibel“, z.B. bei Vergleichen, arithmetischen Operationen etc., Attribute mit verschiedenen Domänen sind nicht kompatibel
  - Praxis: Nicht relevant, die meisten RDBMS unterstützen nur vordefinierte Domänen wie INTEGER, VARCHAR(n) etc. – und das ist auch gut so!
- Aber: Domänen dürfen nur sogenannte «atomare» Werte enthalten, d.h. strukturierte Werte (Mengen, Listen, Vektoren u.ä. nicht zulässig)

**UStudents**

StudNo	Name	Faculty	ProgrammingSkills
'87-604-I'	'Meier'	'Comp Science'	{ 'Java', 'C', 'SQL' }
'91-872-I'	'Schmid'	'Comp Science'	{ 'Pascal', 'Java' }
'91-109-I'	'Anderegg'	'Comp Science'	{ 'Java' }
'94-555-L'	'Imboden'	'Chemistry'	{ }

# Attribute und Wertebereiche

- In der Theorie ist es sinnvoll, die erlaubten Werte einer Domäne möglichst genau zu beschreiben und einzuschränken. Heutige RDBMS unterstützen diese Einschränkungen aber nur teilweise.
- Vorteile? Nachteile?

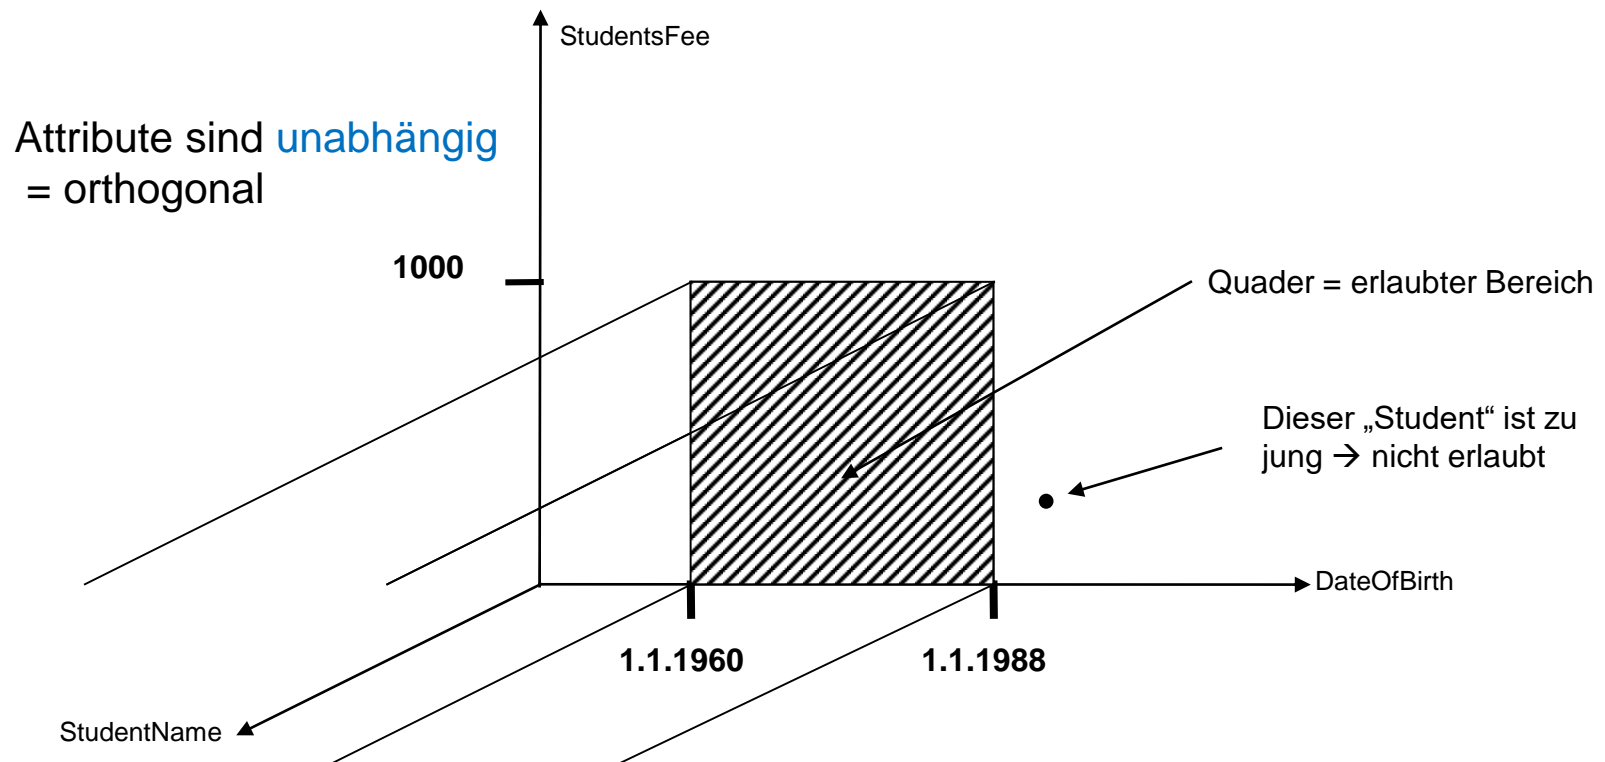
# Attribute und Wertebereiche

- Vorteile von Datentypen: Damit können schon eine Reihe von möglichen Eingabefehlern zentral (statt in jedem einzelnen Anwendungsprogramm) abgefangen werden.
- Beispiel: Studenttyp(*StudentName*, *DateOfBirth*, *StudentsFee*)

$\text{DateOfBirth} \geq \text{'1.1.1960'} \wedge \text{DateOfBirth} \leq \text{'1.1.1988'}$   
 $\text{StudentsFee} \geq 0 \wedge \text{StudentsFee} \leq 1000$


# Unabhängigkeit von Attributen

- Die Attributwerte von Studenttyp(StudentName, DateOfBirth, StudentsFee) können «räumlich» aufgezeichnet werden:





# Unabhängigkeit von Attributen



Ein Vorgriff auf kommende Themen: Ort und Postleitzahl sind **nicht unabhängig**, die Zuordnung ist nicht eindeutig  
→ Könnten theoretisch als 2 Entitätstypen mit einer m:m-Beziehung modelliert werden

# Übersicht, etwas formaler

## Wertebereich (domain):

- Menge einfacher bzw. „atomarer“ Werte (entspricht im wesentlichen einem unstrukturierten Datentyp einer höheren Programmiersprache)
- Gegeben sei eine Menge  $\{D_1, \dots, D_m\}$  von Wertebereichen
- Relation  $r$  besteht aus:
  - Relationenformat: Menge von Namen von Attributen  $\{A_1, \dots, A_n\}$  wobei jedem Attributnamen  $A_i$  eine Domain  $\text{dom}(A_i) \in \{D_1, \dots, D_m\}$  zugeordnet wird
  - Ausprägung (Wert, Extension):  $\text{ext}(r) \subseteq \text{dom}(A_1) \times \dots \times \text{dom}(A_n)$
- Als Domains werden häufig Zahlen (ganze, Gleitkomma-, Fixpunkt-Zahlen) oder Zeichenketten verwendet. Oft werden sie nicht explizit aufgeführt
- Der Wertebereich gilt als zusätzliche Einschränkung der möglichen Attributswerte

# Äquivalenz

- Zwei Relationen sind äquivalent wenn sich die eine durch Umordnen der Attribute der anderen herstellen lässt
- Darstellung:  $R1 \sim R2$
- Bsp:
  - BUCH1(ISBN, Titel, Typ, Jahr, Auflage, Fachgebiet)
  - BUCH2(Titel, Typ, ISBN, Auflage, Jahr, Fachgebiet)
  - $BUCH1 \sim BUCH2$

# Eigenschaften

- Konsequenzen aus Definition, Relationen sind:
  - Duplikatfrei
  - Ungeordnet (Attribute & Tupel)
  - Endlich
- Veranschaulichung in Tabellenform:
  - Spalten = Attribute
  - Zeilen = Tupel

# Begriff: Relationale Algebra

- **Operatoren** und **Regeln** für das «Rechnen» mit Relationen (Analogie: Arithmetik mit Addition, Subtraktion... auf ganzen Zahlen).
- Bis jetzt: Relationenschemas mit Relationen (Attributwerten), die in einer Datenbank gespeichert sind (wie sie dahin kommen folgt später).
- Es fehlt: «Abgeleitete» Relationenschemas mit Relationen, die aus den «Basisrelationen» berechnet werden.
- Die Rechenvorschriften definieren eine «**Abfragesprache**», d.h. eine Sprache, mit der **beliebige** Abfragen an eine Datenbank gestellt werden können.

# Begriff: Relationale Algebra

- Mathematik:
  - Algebra: Definiert durch Wertebereich und auf diesem definierte Operatoren.
  - Operand: Variablen oder Werte aus denen neue Werte konstruiert werden können.
  - Operator: Symbole, die Prozeduren repräsentieren, die aus gegebenen Werten neue Werte produzieren.
- Für Datenbankabfragen:
  - Inhalt der Datenbank (Relationen) sind **Operanden**.
  - **Operatoren** definieren **Funktionen zum Berechnen von Abfrageergebnissen**: «Grundlegenden Dinge, die wir mit Relationen tun wollen».
  - Relationale Algebra (Relationenalgebra, RA).
  - Anfragesprache für das relationale Modell.

# Kriterien für Abfragesprachen

- Ad-Hoc-Formulierung:
  - Benutzer sollen eine Anfrage formulieren können, ohne ein vollständiges Programm schreiben zu müssen.
- Deskriptivität / Deklarativität:
  - Benutzer sollen formulieren „Was will ich haben?“ und nicht „Wo finde ich das, was ich haben will?“
- Optimierbarkeit:
  - Sprache besteht aus wenigen Operationen.
  - Optimierungsregeln für die Operatorenmenge.

# Kriterien für Abfragesprachen

- Abgeschlossenheit:
  - Anfragen erfolgen auf Relationen.
  - Anfrageergebnis ist wiederum **eine Relation** und kann als Eingabe für die nächste Anfrage verwendet werden → Schachtelung möglich.
- Mengenorientiertheit:
  - Operationen auf Mengen von Daten.
  - Nicht navigierend nur auf einzelnen Elementen („tuple-at-a-time“).
- Sicherheit:
  - Keine Anfrage, die syntaktisch korrekt ist, darf in eine Endlosschleife geraten oder ein unendliches Ergebnis liefern.
- ...



# Klassifikation der rel. Operatoren

- Entfernende Operatoren:
  - Selektion, Projektion
- Mengenoperatoren:
  - Vereinigung, Schnittmenge, Differenz
- Kombinerende Operatoren:
  - Kartesisches Produkt, Join, Joinvarianten
- Umbenennung:
  - Verändert nicht Tupel, sondern Schema
- Ausdrücke der relationalen Algebra: „Anfragen“ (queries)

# Einschub: Griechisches Alphabet

Name	Zeichen	Name	Zeichen	Name	Zeichen
Alpha	A, $\alpha$	Iota	I, $\iota$	Rho	P, $\rho$
Beta	B, $\beta$	Kappa	K, $\kappa$	Sigma	$\Sigma$ , $\sigma$
Gamma	$\Gamma$ , $\gamma$	Lambda	$\Lambda$ , $\lambda$	Tau	T, $\tau$
Delta	$\Delta$ , $\delta$	My	M, $\mu$	Ypsilon	$\Upsilon$ , $\upsilon$
Epsilon	E, $\epsilon$	Ny	N, $\nu$	Phi	$\Phi$ , $\phi$
Zeta	Z, $\zeta$	Xi	$\Xi$ , $\xi$	Chi	X, $\chi$
Eta	H, $\eta$	Omikron	O, $o$	Psi	$\Psi$ , $\psi$
Theta	$\Theta$ , $\vartheta$	Pi	$\Pi$ , $\pi$	Omega	$\Omega$ , $\omega$

# Symbole der relationalen Algebra

## Übersicht der Operationen:

- $\sigma$  Selektion
- $\pi$  Projektion
- $\times$  Kreuzprodukt
- $\bowtie$  Join (Verbund)
- $\setminus$  Mengendifferenz
- $\cup$  Mengenvereinigung
- $\cap$  Mengendurchschnitt
- $\div$  Division
- $\rho$  Umbenennung
- Linker äusserer Verbund (Symbol, oft weggelassen:  $\bowtie$  )
- Rechter äusserer Verbund (Symbol, oft weggelassen:  $\bowtie$  )
- Voller äusserer Verbund (Symbol, oft weggelassen:  $\bowtie$  )

# Entfernend: Selektion, $\sigma$

- Unärer Operator (d.h. nur ein Operand)
- Erzeugt neue Relation mit **gleichem Schema** aber einer Teilmenge der Tupel.
- Nur Tupel, die der sogenannten **Selektionsbedingung** entsprechen, werden übernommen.
- Selektionsbedingung: Kombination von logischen Ausdrücken bestehend aus Attributen und/oder Konstanten (das Ergebnis des Ausdrucks muss wahr oder falsch sein).
- Prüft Selektionsbedingung **für jedes Tupel** der Relation.

# Entfernend: Selektion, $\sigma$

<b>Filme</b>					
<b>Titel</b>	<b>Jahr</b>	<b>Länge</b>	<b>inFarbe</b>	<b>Studio</b>	<b>ProduzentID</b>
Total Recall	1990	113	True	Fox	12345
Basic Instinct	1992	127	True	Disney	67890
Dead Man	1995	90	False	Paramount	99999

$\sigma_{\text{Länge} \geq 100}(\text{Filme})$

<b>Titel</b>	<b>Jahr</b>	<b>Länge</b>	<b>inFarbe</b>	<b>Studio</b>	<b>ProduzentID</b>
Total Recall	1990	113	True	Fox	12345
Basic Instinct	1992	127	True	Disney	67890

© F.Naumann, 2011

# Entfernend: Selektion, $\sigma$

**Customers**

CNo	Name	City	Balance	Discount
1	'Legrand'	'Genève'	0.00	0.10
2	'Studer'	'Zürich'	-800.00	0.20
3	'Huber'	'Zürich'	-20.00	0.05

Finde alle Zürcher Kunden, die einen Rabatt von 15% oder mehr erhalten

$\sigma_{\text{City} = \text{'Zürich'} \wedge \text{Discount} \geq 0.15}$  Customers

CNo	Name	City	Balance	Discount
2	'Studer'	'Zürich'	-800.00	0.20

# Entfernend: Projektion, $\pi$

- Unärer Operator (d.h. nur ein Operand).
- Erzeugt neue Relation mit einer **Teilmenge der ursprünglichen Attribute**
  - $\pi_{A1,A2,\dots,Ak}(R)$  ist eine Relation mit den Attributen  $A1,A2,\dots,Ak$
- Achtung: Es können **Duplikate** entstehen, die **entfernt** werden müssen.
- Die Projektion wählt eine Menge von Spalten aus (und entfernt die Übrigen).
- Mit einer Projektion lässt sich auch die **Reihenfolge** der Spalten anpassen.

# Entfernend: Projektion, $\pi$

Filme					
Titel	Jahr	Länge	inFarbe	Studio	ProduzentID
Total Recall	1990	113	True	Fox	12345
Basic Instinct	1992	127	True	Disney	67890
Dead Man	1995	121	False	Paramount	99999

 $\pi_{\text{Titel, Jahr, Länge}}(\text{Filme})$ 

Titel	Jahr	Länge
Total Recall	1990	113
Basic Instinct	1992	127
Dead Man	1995	121

 $\pi_{\text{inFarbe}}(\text{Filme})$ 

inFarbe
True
False



# Aufgabe zur Projektion

- Aufgabe: Es sei **Clubs** = {<Tischtennis, 1.10.1990, 15.00>, <Schwimmclub, 31.7.1988, 10.00>, <PC, 1.10.1990, 15.00>}.  
  
• Relationenformat Clubtyp(Clubname, Gründungsdatum, Jahresbeitrag)

**?** Wie sieht die Relation  $\pi_{\text{Gründungsdatum, Jahresbeitrag}}(\text{Clubs})$  aus?

# Resultat

- Man beachte:
- $\pi_{\text{Gründungsdatum, Jahresbeitrag}}(\text{Clubs}) = \{ \langle 1.10.1990, 15.00 \rangle, \langle 31.7.1988, 10.00 \rangle \}$
- Die Ergebnisrelation besteht aus **zwei** Tupeln, nicht etwa drei.

**?** Wieso?

# Bemerkung

- Relationen sind **Mengen**. Mengen können keine **doppelten Elemente** enthalten!
- Die Projektion eliminiert **Duplikate**.
- Aber Achtung: Relationale Datenbankverwaltungssysteme eliminieren mehrfach vorkommende Tupel bei der Projektion **nicht automatisch**. Man spricht dann (präziser) nicht von Relationen sondern von (**relationalen**) **Bags** (= Multimengen)
- Es gilt auch:  $\sigma_{\phi_1}(\sigma_{\phi_2}(r)) = \sigma_{\phi_2}(\sigma_{\phi_1}(r))$
- Hingegen gilt nicht:  $\pi_A(\pi_B(r)) = \pi_B(\pi_A(r))$

# Und weiter..

## Das nächste Mal: Relationale Algebra (Fortsetzung)

