



Information Engineering 1: Information Retrieval

Kapitel 8: Ausblick

Conversational IR

M. Braschler

"Themenkarte"



- Ein Ausblick auf ein kommendes, heisses Thema
- Quellen:
 - Recent Advances in Conversational Information Retrieval (CIR) A review of neural approaches, Jianfeng Gao, Chenyan Xiong, Paul Bennett, Microsoft Research, SIGIR 2020
 - CAsT 2019: The Conversational Assistance Track Overview, Jeffrey, Chenyan Xiong, Jamie Callan, NIST TREC Proceedings

Themen:

- Conversational IR?
- Vision
- Aktueller Ansatz
- Ausblick



Lernziel Kapitel

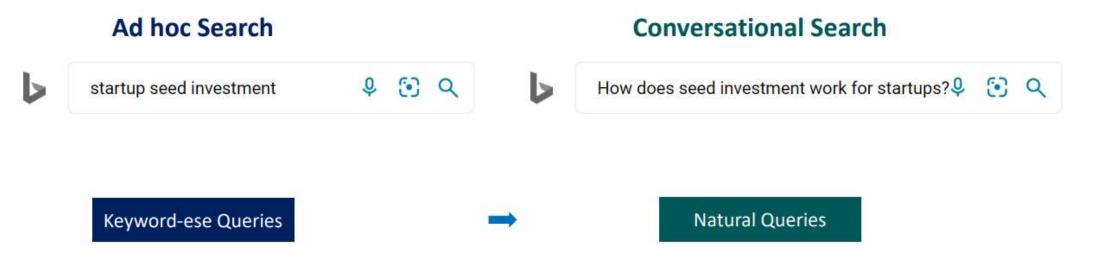
- Kennen: was kommt in den n\u00e4chsten Jahren auf das Feld Information Retrieval zu?
- Verstehen: Bezug zu den gelernten Basics

Zürcher Fachhochschule

Die nächste Generation IR?



Natürlichere Anfragen statt «Keywords»

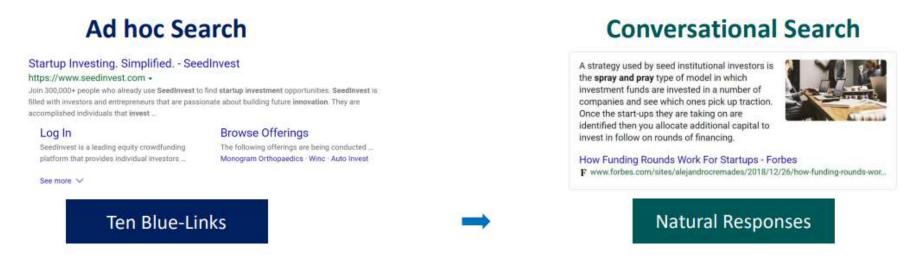


- Voraussetzung: Sprachinterfaces
- Chancen: Natürlichere, explizitere Darstellung des Informationsbedürfnisses
- Herausforderung: Query Understanding

Die nächste Generation IR?



Antworten, nicht Ranglisten



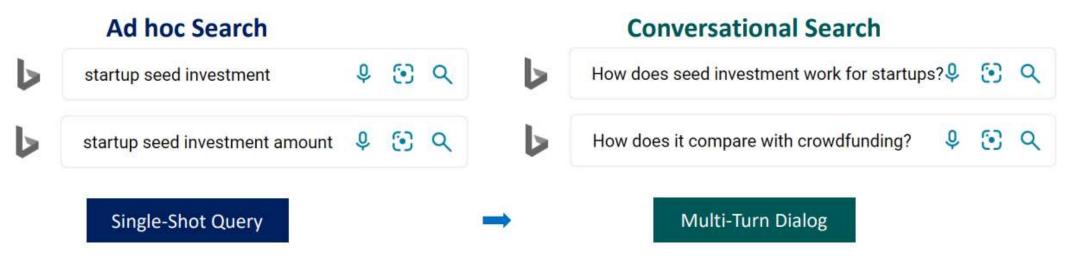
- Voraussetzung: Sprachinterfaces
- Chancen: Direkterer, leichterer Zugang zur Information
- Herausforderung: Document Understanding, Informationssynthese



Zürcher Hochschule

Die nächste Generation IR?

Konversation, nicht «Single Shot»



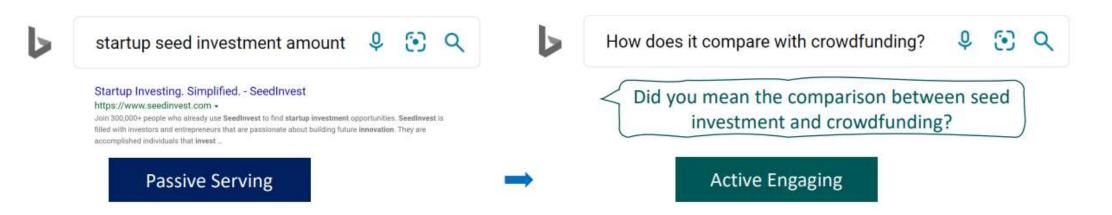
- Chancen: Komplexere Informationsbedürfnisse bedienen
- Herausforderung: Contextual Understanding, «Gedächtnis»

Zürcher Hochschule für Angewandte Wissenschaften



Die nächste Generation IR?

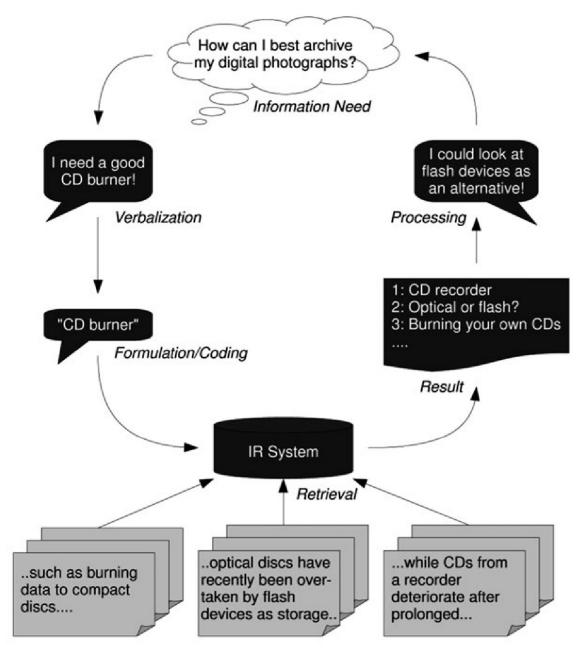
Aktiver, nicht passiver, Dialog



- Chancen: Bessere, direktere Resultate
- Herausforderung: Dialog Management, User Experience muss stimmen

zh aw

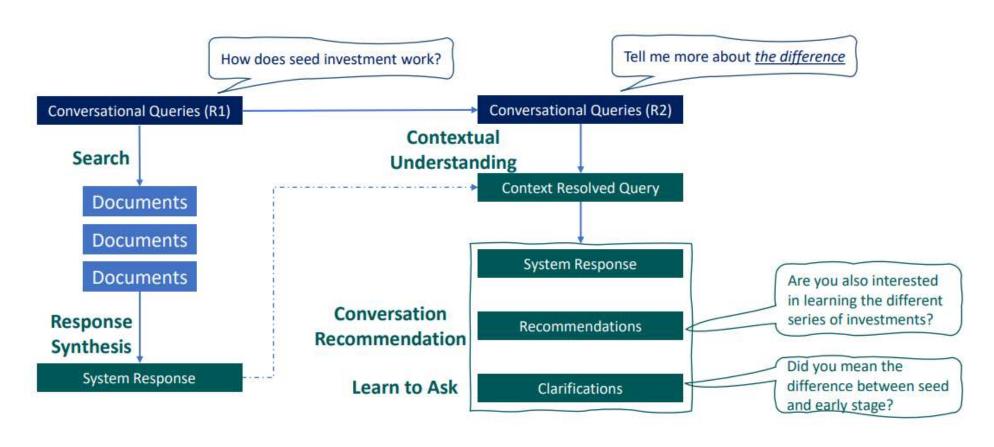
Rückblick: IR-Kreislauf



Aus Peters et al., 2012



Conversational IR: Vision

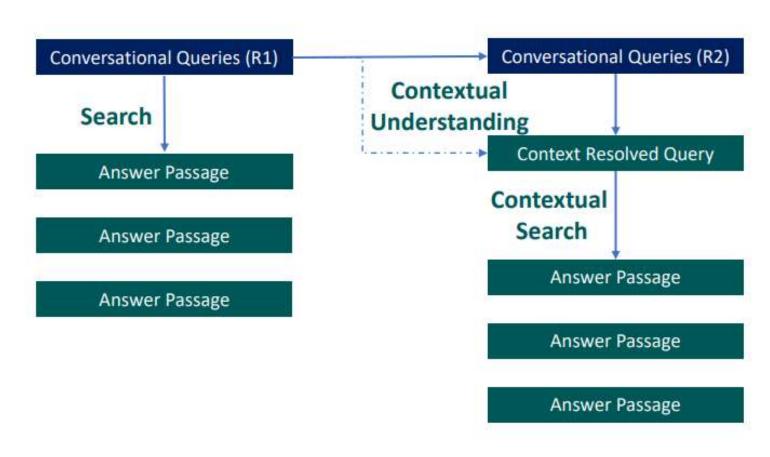






Conversational IR: Simpler Ansatz

Der tatsächliche, heutige Ansatz







Beispielanfrage

TREC CAsT («Conversational Assistance Track»)

~20 Queries mit je ~8 «Runden», Korpus aus Passagen

Title: head and neck cancer

Description: A person is trying to compare and contrast types of cancer in the throat, esophagus, and lungs.

- 1 What is throat cancer?
- 2 Is it treatable?
- 3 Tell me about lung cancer.
- 4 What are its symptoms?
- 5 Can it spread to the throat?
- 6 What causes throat cancer?
- 7 What is the first sign of it?
- 8 Is it the same as esophageal cancer?

9 What's the difference in their symptoms?



Query Rewriting



Herausforderung: kontextuelle Abhängigkeit zu früheren Anfragen

Title: head and neck cancer

Description: A person is trying to compare and contrast types of cancer in the throat, esophagus, and lungs.

- 1 What is throat cancer?
- 2 Is it treatable?
- 3 Tell me about lung cancer.
- 4 What are its symptoms?
- 5 Can it spread to the throat?
- 6 What causes throat cancer?
- 7 What is the first sign of it?
- 8 Is it the same as esophageal cancer?
- 9 What's the difference in **their** symptoms?

Manual Queries provided by CAsT Y1

- 1 What is throat cancer?
- 2 Is throat cancer treatable?
- 3 Tell me about lung cancer.
- 4 What are lung cancer's symptoms?
- 5 Can <u>lung cancer</u> spread to the throat
- 6 What causes throat cancer?
- 7 What is the first sign of throat cancer?
- 8 Is throat cancer the same as esophageal cancer?
- 9 What's the difference in <u>throat cancer and</u> <u>esophageal cancer's</u> symptoms?

Probleme mit Query Rewriting



Es gibt nicht immer wirklich etwas, was umgeschrieben werden kann

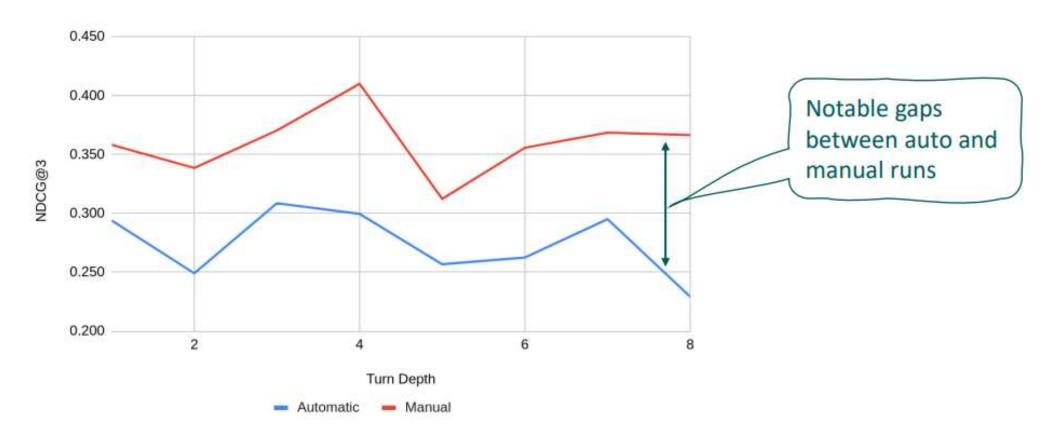
Type (#. Turns)	Utterance	Mention
Pronominal (128)	How do they celebrate Three Kings Day?	they -> Spanish people
Zero (111)	What cakes are traditional?	Null -> Spanish, Three Kings Day
Groups (4)	Which team came first?	which team -> Avengers, Justice League
Abbreviations (15)	What are the main types of VMs ?	VMs -> Virtual Machines

Manchmal auch einfach impliziten Kontext einbeziehen

State of the Art



 Query Understanding (oder Query Rewriting) ist schwer – die Fehler machen sich in späten Runden besonders bemerkbar.

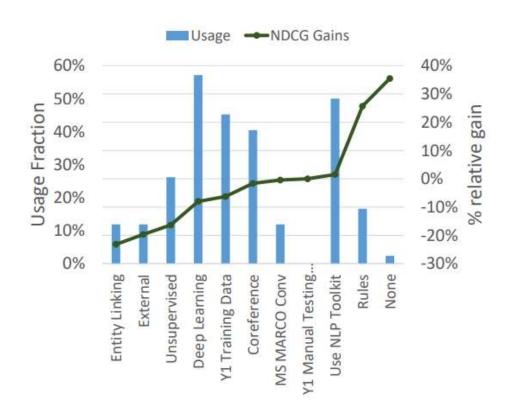




State of the Art



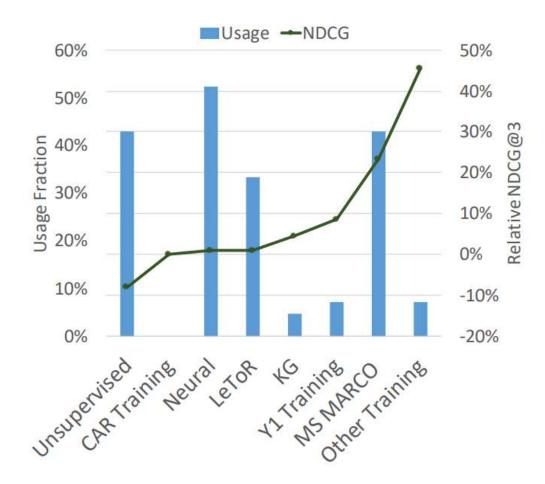
- Query Rewriting:
 - Deep Learning-Ansätze negativ korreliert
 - Heuristische Regeln am effektivsten



Ranking



Für das Ranking ist der Einbezug von externen Daten besonders effektiv



State of the Art



- Der Einsatz von Techniken wie Transformern ist in diesem Kontext aufgrund der sehr spärlichen Trainingsdaten eingeschränkt (nur 50 Topics, nur je 10 Turns)
- Idee: wir verwenden Daten aus den Logs klassischer Suchmaschinen für das Training. Dazu werden diese «Conversationalisiert» → MS MARCO Dataset

zh

State of the Art

 Auf diesen «Pseudo-conversational» Queries kann das geübt werden, die für sich selbst stehenden Queries zu generieren

Q_6	What causes throat cancer?	
Q_7	What is the first sign of it?	
Q_8	Is it the same as esophageal cancer ?	
Q_9	What's the difference in $\underline{\text{their}}$ symptoms?	
Oracle	What's the difference in throat cancer and esophageal cancer's symptoms?	
Output	What's the difference between throat cancer and esophageal cancer?	

Q_1	What are the types of pork ribs ?
Q_2	What are baby backs?
Q_3	What are the differences with spareribs?
Q_4	What are ways to cook them?
Q_5	How <u>about</u> on the bbq?
Oracle	How do you cook pork ribs on the bbq?
Output	How about on the bbq?

Ausblick



Findet Conversational Search heute statt?

Nein, die meisten Queries sind nicht «conversational»

- Nutzer/innen sind darauf getrimmt, Stichworte zu verwenden

Die Suche muss neu gedacht werden. «Für die Konversation nützlich» != relevant!

Beispiel «People also asked»: Für Query «Nissan GTR»



Zürcher Hochschule für Angewandte Wissenschaften



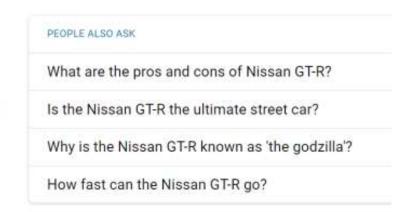
Fazit

- Letztlich ein weiterer Schritt weg von «Pattern Matching» zu echtem Information Retrieval
- Was wir über IR gelernt haben, bleibt gülitg: auch für «Conversational Queries» muss Retrieval gemacht werden. Aber wir kommen näher an den Kreislauf aus Kapitel 1.

Relevant



Relevant & Useful





Ende

Hier endet die Theorie des Moduls «Information Engineering 1» Vielen Dank für Ihr Interesse und Ihre Beiträge!



Quelle: Wikimedia Commons