

Theoretische Informatik

Teil 4

Kontextfreie Grammatiken

Frühlingssemester 2019

L. Di Caro

D. Flumini

O. Stern

- Die Studierenden können **kontextfreie Grammatiken (KFG)** formal und an Beispielen erklären. Sie können für einfache gegebene Sprachen eine zugehörige Grammatik entwerfen.
- Die Studierenden kennen **Ableitungen** für KFG, können Beispiele dazu angeben und den Begriff der **Mehrdeutigkeit** einer KFG erklären.
- Sie können die **Sprache einer KFG** definieren und den Zusammenhang zu den regulären Ausdrücken (RA) angeben.

- Einführung und Definition
- Ableitungsschritt, Ableitung
- Rechtseitige und linksseitige Ableitungen
- Sprache eine KFG
- Ableitungsbaum
- Mehrdeutigkeit (von KFG)
- Zusammenhang von KFG und regulären Ausdrücken
- Anwendungen

Motivation:

- Es wurde bereits gezeigt, dass es nicht-reguläre Sprachen gibt, d. h. Sprachen, die mächtiger als RA sind bzw. sich nicht durch einen RA beschreiben lassen.
- $\{0^n 1^n \mid n \in \mathbb{N}\}$ ist ein Beispiel für eine einfache nicht-reguläre Sprache (vgl. Abschnitt EA).

Motivation:

- Es wurde bereits gezeigt, dass es nicht-reguläre Sprachen gibt, d. h. Sprachen, die mächtiger als RA sind bzw. sich nicht durch einen RA beschreiben lassen.
- $\{0^n 1^n \mid n \in \mathbb{N}\}$ ist ein Beispiel für eine einfache nicht-reguläre Sprache (vgl. Abschnitt EA).

⇒ Dennoch lässt sich diese Sprache bzw. Vorschrift zur Erzeugung eigentlich leicht beschreiben.

Wie könnte eine solche Beschreibung informell lauten?

Beispiel

Kontextfreie Grammatik für die nicht-reguläre Sprache $\{0^n 1^n \mid n \in \mathbb{N}\}$:

Beispiel

Kontextfreie Grammatik für die nicht-reguläre Sprache $\{0^n1^n \mid n \in \mathbb{N}\}$:

$$A \rightarrow 0A1$$

$$A \rightarrow \varepsilon$$

Beispiel

Kontextfreie Grammatik für die nicht-reguläre Sprache $\{0^n 1^n \mid n \in \mathbb{N}\}$:

$$A \rightarrow 0A1$$

$$A \rightarrow \varepsilon$$

Eine Ableitung des Wortes 000111 in der Grammatik:

Beispiel

Kontextfreie Grammatik für die nicht-reguläre Sprache $\{0^n 1^n \mid n \in \mathbb{N}\}$:

$$A \rightarrow 0A1$$

$$A \rightarrow \varepsilon$$

Eine Ableitung des Wortes 000111 in der Grammatik:

$$A \Rightarrow 0A1 \Rightarrow 00A11 \Rightarrow 000A111 \Rightarrow 000111$$

Beispiel

Kontextfreie Grammatik für die nicht-reguläre Sprache $\{0^n1^n \mid n \in \mathbb{N}\}$:

$$A \rightarrow 0A1$$

$$A \rightarrow \varepsilon$$

Eine Ableitung des Wortes 000111 in der Grammatik:

$$A \Rightarrow 0A1 \Rightarrow 00A11 \Rightarrow 000A111 \Rightarrow 000111$$

Anmerkung: Alle Wörter, die wir in der Grammatik ableiten können, bilden die Sprache der Grammatik.

Definition (Kontextfreie Grammatik)

Eine **kontextfreie Grammatik** G (KFG) ist ein 4-Tupel (N, Σ, P, S) mit

- N ist das Alphabet der **Nichtterminale** (Variablen).
- Σ ist das Alphabet der **Terminale**.
- P ist eine endliche Menge von **Produktionen** (Regeln). Jede Produktion hat die Form

$$X \rightarrow \beta$$

mit **Kopf** $X \in N$ und **Rumpf** $\beta \in (N \cup \Sigma)^*$.

- S ist das **Startsymbol**, wobei $S \in N$.

Definition (Satzform)

Ein Wort $\beta \in (N \cup \Sigma)^*$ nennen wir **Satzform**.

Beispiel

Eine KFG G_1 für die Sprache $\{0^n 1^n \mid n \in \mathbb{N}\}$:

Beispiel

Eine KFG G_1 für die Sprache $\{0^n 1^n \mid n \in \mathbb{N}\}$:

$$G_1 = (\{A\}, \{0, 1\}, P, A)$$

mit

$$P = \{A \rightarrow 0A1, A \rightarrow \varepsilon\}$$

Beispiel

Eine KFG G_1 für die Sprache $\{0^n 1^n \mid n \in \mathbb{N}\}$:

$$G_1 = (\{A\}, \{0, 1\}, P, A)$$

mit

$$P = \{A \rightarrow 0A1, A \rightarrow \varepsilon\}$$

Anmerkung: Mehrere Regeln mit dem gleichen Nichtterminal im Kopf können wir kompakt notieren:

$$A \rightarrow 0A1 \mid \varepsilon$$

Beispiel

Eine KFG G_2 für die Sprache der balancierten Klammerausdrücke wie zum Beispiel $((()))()$:

Beispiel

Eine KFG G_2 für die Sprache der balancierten Klammerausdrücke wie zum Beispiel $((()))()$:

$$G_2 = (\{A\}, \{(\,,\,)\}, P, A)$$

Die Menge der Produktionen P ist

$$A \rightarrow (A) \mid AA \mid \varepsilon$$

Beispiel

Eine KFG G_2 für die Sprache der balancierten Klammerausdrücke wie zum Beispiel $((()))()$:

$$G_2 = (\{A\}, \{(\,,\,)\}, P, A)$$

Die Menge der Produktionen P ist

$$A \rightarrow (A) \mid AA \mid \varepsilon$$

Beispiel (Ableitung des Wortes $((()))()$ in G)

Beispiel

Eine KFG G_2 für die Sprache der balancierten Klammerausdrücke wie zum Beispiel $((()))()$:

$$G_2 = (\{A\}, \{(\,,\,)\}, P, A)$$

Die Menge der Produktionen P ist

$$A \rightarrow (A) \mid AA \mid \varepsilon$$

Beispiel (Ableitung des Wortes $((()))()$ in G)

$$A \Rightarrow AA \Rightarrow (A)A \Rightarrow (A)(A) \Rightarrow ((A))(A) \Rightarrow (())(A) \Rightarrow (()())$$

Definition

Seien α , β und γ Satzformen und $A \rightarrow \gamma$ eine Produktion.

- Durch einen **Ableitungsschritt** wird eine Satzform $\alpha A \beta$ durch die Anwendung der Produktion $A \rightarrow \gamma$ in die Satzform $\alpha \gamma \beta$ **abgeleitet**. Das notieren wir mit

$$\alpha A \beta \Rightarrow \alpha \gamma \beta$$

- Eine **Ableitung** ist eine Folge von Ableitungsschritten, so dass aus einer Satzform α das Wort w abgeleitet wird.

$$\alpha \Rightarrow \dots \Rightarrow w$$

Definition

- Eine **linksseitige Ableitung** ersetzt bei jedem Ableitungsschritt das Nichtterminal, das am weitesten *links* in der Satzform auftritt.
- Eine **rechtsseitige Ableitung** ersetzt bei jedem Ableitungsschritt das Nichtterminal, das am weitesten *rechts* in der Satzform auftritt.

Definition

- Eine **linksseitige Ableitung** ersetzt bei jedem Ableitungsschritt das Nichtterminal, das am weitesten *links* in der Satzform auftritt.
- Eine **rechtsseitige Ableitung** ersetzt bei jedem Ableitungsschritt das Nichtterminal, das am weitesten *rechts* in der Satzform auftritt.

Beispiel (Linksseitige Ableitung)

$$A \Rightarrow AA \Rightarrow$$

Definition

- Eine **linksseitige Ableitung** ersetzt bei jedem Ableitungsschritt das Nichtterminal, das am weitesten *links* in der Satzform auftritt.
- Eine **rechtsseitige Ableitung** ersetzt bei jedem Ableitungsschritt das Nichtterminal, das am weitesten *rechts* in der Satzform auftritt.

Beispiel (Linksseitige Ableitung)

$$A \Rightarrow AA \Rightarrow (A)A \Rightarrow ((A))A \Rightarrow (())A \Rightarrow (())(A) \Rightarrow (())()$$

Definition

Ein Wort $w \in \Sigma^*$ ist in einer kontextfreien Grammatik $G = (N, \Sigma, P, S)$ **ableitbar**, falls es eine Ableitung in G gibt, die mit dem Startsymbol S beginnt und mit dem Wort w endet. Dafür schreiben wir

$$S \xRightarrow{*} w$$

Wir sagen auch, dass w von S **erzeugt** oder **generiert** wird.

Definition (Sprache einer kontextfreien Grammatik)

Die von G **erzeugte Sprache** $L(G)$ beinhaltet alle Wörter, die in G aus dem Startsymbol S ableitbar sind.

$$L(G) = \{ w \in \Sigma^* \mid S \xRightarrow{*} w \}$$

Definition (Sprache einer kontextfreien Grammatik)

Die von G **erzeugte Sprache** $L(G)$ beinhaltet alle Wörter, die in G aus dem Startsymbol S ableitbar sind.


$$L(G) = \{ w \in \Sigma^* \mid S \xRightarrow{*} w \}$$

Definition (Kontextfreie Sprache)

Wenn es für eine Sprache L eine kontextfreie Grammatik G gibt mit $L = L(G)$, dann nennen wir L eine **kontextfreie Sprache**.


Ein **Ableitungsbaum** ist eine graphische Darstellung einer Ableitung.

Beispiel (Ableitungsbaum für das Wort $((()))$ in G_2)



Ein **Ableitungsbaum** ist eine graphische Darstellung einer Ableitung.

Beispiel (Ableitungsbaum für das Wort $((()))$ in G_2)



Anmerkungen:

- Ableitungsbäume werden typischerweise von Compilern als Datenstruktur für die interne Repräsentation von Quellprogrammen erzeugt.
- Sie werden auch als *Parsebäume* bezeichnet.
- Sie verdeutlichen, wie Symbole der terminalen Zeichenreihen bzw. Satzformen einer KFG in Teilzeichenreihen strukturiert werden.


Beispiel (Kontextfreie Grammatik für arithmetische Ausdrücke)

$$A \rightarrow A + A \quad A \rightarrow A \cdot A \quad A \rightarrow (A) \quad A \rightarrow a$$

Beispiel (Kontextfreie Grammatik für arithmetische Ausdrücke)

$$A \rightarrow A + A \quad A \rightarrow A \cdot A \quad A \rightarrow (A) \quad A \rightarrow a$$

Das Wort $a + a \cdot a$ kann durch zwei verschiedene Ableitungsbäume dargestellt werden.



Ein Wort, das mehrere Ableitungsbäume besitzt, hat auch mehrere linksseitige (rechtsseitige) Ableitungen.

Beispiel

Zwei linksseitige Ableitungen für $a + a \cdot a$:

- $A \Rightarrow A \cdot A \Rightarrow A + A \cdot A \Rightarrow a + A \cdot A \Rightarrow \dots$
- $A \Rightarrow A + A \Rightarrow a + A \Rightarrow a + A \cdot A \Rightarrow \dots$

Definition (Mehrdeutige kontextfreie Grammatik)

Eine kontextfreie Grammatik nennen wir **mehrdeutig**, wenn es ein Wort gibt, das mehrere Ableitungsbäume besitzt.

Definition (Mehrdeutige kontextfreie Grammatik)

Eine kontextfreie Grammatik nennen wir **mehrdeutig**, wenn es ein Wort gibt, das mehrere Ableitungsbäume besitzt.

Möglichkeiten, die Mehrdeutigkeit von KFG zu eliminieren:

Definition (Mehrdeutige kontextfreie Grammatik)

Eine kontextfreie Grammatik nennen wir **mehrdeutig**, wenn es ein Wort gibt, das mehrere Ableitungsbäume besitzt.

Möglichkeiten, die Mehrdeutigkeit von KFG zu eliminieren:

- Korrekte Klammerung vom Benutzer erzwingen:
z. B. $a + (a \cdot a)$ statt $a + a \cdot a$

Definition (Mehrdeutige kontextfreie Grammatik)

Eine kontextfreie Grammatik nennen wir **mehrdeutig**, wenn es ein Wort gibt, das mehrere Ableitungsbäume besitzt.

Möglichkeiten, die Mehrdeutigkeit von KFG zu eliminieren:

- Korrekte Klammerung vom Benutzer erzwingen:
z. B. $a + (a \cdot a)$ statt $a + a \cdot a$
- Grammatik anpassen (z. B. "Terme", "Faktoren")

Definition (Mehrdeutige kontextfreie Grammatik)

Eine kontextfreie Grammatik nennen wir **mehrdeutig**, wenn es ein Wort gibt, das mehrere Ableitungsbäume besitzt.

Möglichkeiten, die Mehrdeutigkeit von KFG zu eliminieren:

- Korrekte Klammerung vom Benutzer erzwingen:
z. B. $a + (a \cdot a)$ statt $a + a \cdot a$
- Grammatik anpassen (z. B. "Terme", "Faktoren")
- Den Produktionen einen Vorrang vergeben:
z. B. $A \rightarrow A + A$ den Vorrang über $A \rightarrow A \cdot A$ geben

Definition (Inhärent mehrdeutig)

Eine kontextfreie Sprache, für die alle Grammatiken mehrdeutig sind, heisst **inhärent mehrdeutig**.

Beispiel (Inhärent mehrdeutige Sprache)


$$\{ a^i b^j c^k \mid i = j \text{ oder } j = k \}$$

Theorem

Die kontextfreien Sprachen enthalten die regulären Sprachen.

Beweisidee.

Jede reguläre Sprache kann durch eine kontextfreie Grammatik beschrieben werden. □



Sei L eine reguläre Sprache. Dann gibt es einen DEA $M = (Q, \Sigma, \delta, q_0, F)$ mit $L(M) = L$.

Dann können wir eine KFG für L wie folgt bauen:

- 1 Für jeden Zustand q_i gibt es ein Nichtterminal Q_i .
- 2 Für jede Transition $\delta(q_i, a) = q_j$ erstellen wir die Produktion $Q_i \rightarrow aQ_j$.
- 3 Für jeden akzeptierenden Zustand $q_i \in F$ erstellen wir die Produktion $Q_i \rightarrow \varepsilon$.
- 4 Das Nichtterminal Q_0 wird zum Startsymbol.

Beispiel


$$L = \{ w \in \{0,1\}^* \mid |w|_1 \bmod 3 = 0 \}$$

Beispiel

$L = \{ w \in \{0,1\}^* \mid |w|_1 \bmod 3 = 0 \}$

Nichtterminale: Q_0, Q_1, Q_2

Produktionen:



Beispiel

$L = \{ w \in \{0, 1\}^* \mid |w|_1 \bmod 3 = 0 \}$


Nichtterminale: Q_0, Q_1, Q_2

Produktionen:

$Q_0 \rightarrow 0Q_0 \mid 1Q_1 \mid \varepsilon$

$Q_1 \rightarrow 0Q_1 \mid 1Q_2$

$Q_2 \rightarrow 0Q_2 \mid 1Q_0$



Beispiel

$L = \{ w \in \{0, 1\}^* \mid |w|_1 \bmod 3 = 0 \}$


Nichtterminale: Q_0, Q_1, Q_2

Produktionen:

$Q_0 \rightarrow 0Q_0 \mid 1Q_1 \mid \varepsilon$

$Q_1 \rightarrow 0Q_1 \mid 1Q_2$

$Q_2 \rightarrow 0Q_2 \mid 1Q_0$



Beispiel für Ableitung von $w = 10011$:

$Q_0 \Rightarrow 1Q_1 \Rightarrow 10Q_1 \Rightarrow 100Q_1 \Rightarrow 1001Q_2 \Rightarrow 10011Q_0 \Rightarrow 10011$

Techniken für den Entwurf von kontextfreien Grammatiken:

- Komplexe KFGs können oft in mehrere einfachere KFGs aufgeteilt werden und danach mit der Regel $S \rightarrow S_1 \mid S_2 \mid \dots \mid S_k$ kombiniert werden.
- Um eine KFG für eine reguläre Sprache zu erstellen, kann zuerst ein DEA erstellt werden und dieser dann in eine KFG umgewandelt werden.
- Kontextfreie Sprachen enthalten manchmal Teilwörter, die voneinander „abhängig“ sind. Eine KFG für diese Situation kann mit einer Regel $R \rightarrow uRv$ behandelt werden.
- Komplexere Sprachen sind meist rekursiv aufgebaut. Steht zum Beispiel das Nichtterminal A für einen Ausdruck, kann A wiederum überall dort verwendet werden, wo dieser Ausdruck erlaubt ist.

Techniken für den Entwurf von kontextfreien Grammatiken:

Anmerkung: Ein häufiger Fehler beim Entwurf einer KFG besteht darin, dass neben den Wörtern einer Sprache auch Wörter erzeugt werden können, die nicht zu der Sprache gehören.

■ **Compiler / Parsergeneratoren**

Teil der Syntaxanalyse: z. B. Erkennen von Programmstrukturen wie Klammern, Bedingungen (*if – else*), Blöcke (*begin – end*) . . .

■ **Compiler / Parsergeneratoren**

Teil der Syntaxanalyse: z. B. Erkennen von Programmstrukturen wie Klammern, Bedingungen (*if – else*), Blöcke (*begin – end*) . . .

Frage: Wie lautet eine KFG für die Erkennung von *if – else* Blöcken, wenn *else* optional ist?

■ Compiler / Parsergeneratoren

Teil der Syntaxanalyse: z. B. Erkennen von Programmstrukturen wie Klammern, Bedingungen (*if – else*), Blöcke (*begin – end*) ...

Frage: Wie lautet eine KFG für die Erkennung von *if – else* Blöcken, wenn *else* optional ist?

Mögliche Lösung:

$$G = \{\{A\}, \{if, else\}, P, A\} \text{ mit } P = A \rightarrow AA \mid ifAelse \mid ifA \mid \varepsilon$$

■ Compiler / Parsergeneratoren

Teil der Syntaxanalyse: z. B. Erkennen von Programmstrukturen wie Klammern, Bedingungen (*if – else*), Blöcke (*begin – end*) ...

Frage: Wie lautet eine KFG für die Erkennung von *if – else* Blöcken, wenn *else* optional ist?

Mögliche Lösung:

$$G = \{\{A\}, \{if, else\}, P, A\} \text{ mit } P = A \rightarrow AA \mid ifAelse \mid ifA \mid \varepsilon$$

■ Markup-Sprachen (z. B. HTML), XML ...

Anmerkung: Für die Anwendung sind insbesondere nicht mehrdeutige KFGs von Interesse, da z. B. Compiler und Parser deterministisch arbeiten müssen. Ableitungsbäume stellen die interne Datenstruktur für die Repräsentation von Quellprogrammen dar.